

Licenciatura en Ciencia de Datos

Calidad y Preprocesamiento de Datos

Profesores: MCIC Víctor Manuel Corza Vargas · MCIC Fernando Avitúa Varela

Farmacovigilancia Computacional: Identificación de Subestructuras Moleculares Compartidas en Medicamentos con Reacciones Adversas Comunes mediante un Framework de Calidad de Datos tdqm

Proyecto Final

Fuentes de datos:	SIDER 4.1 (Kuhn et al., 2016) + PUBCHEM (Kim et al., 2023)
Framework metodológico:	Total Data Quality Management (TDQM)
Stack técnico:	Python 3 · pandas · RDKit · recordlinkage · sklearn
Fecha de entrega:	27 de mayo de 2026

“La calidad de los datos no es un lujo técnico; es una condición de supervivencia en sistemas donde las decisiones afectan vidas humanas.”

Resumen Ejecutivo

La farmacovigilancia computacional se enfrenta a un reto estructural: las bases de datos que registran reacciones adversas a medicamentos y las que describen la estructura molecular de esos mismos medicamentos son fuentes heterogéneas, mantenidas por organizaciones distintas, con convenciones de nomenclatura incompatibles. Este proyecto construye un pipeline completo de calidad y preprocesamiento de datos que integra SIDER 4.1 —163,206 pares fármaco-reacción adversa en terminología MEDDRA— con PUBCHEM —1,556 estructuras moleculares en formato SMILES— para responder la pregunta: *¿Comparten subestructuras moleculares los medicamentos que causan el mismo tipo de reacción adversa?*

El trabajo aplica el framework TDQM en sus cuatro fases (Definir, Medir, Analizar, Mejorar) sobre cinco dimensiones de calidad: completitud, consistencia, exactitud, unicidad y validez. Se identificaron y resolvieron los siguientes problemas: (1) 10,447 registros duplicados (6.4 %) causados por la codificación de estereoisómeros en los identificadores STITCH; (2) heterogeneidad semántica cuantificada con similitud Jaro-Winkler, donde el 54.1 % de los pares de nombres presentó índices menores a 0.50; (3) ausencia total del campo *severity* en la fuente base, subsanada mediante imputación desde `meddra_freq.tsv` llevando la cobertura del 0 % al 41.4 %; (4) validación estructural de todas las cadenas SMILES con RDKit, obteniendo 100 % de validez.

El modelo canónico resultante (`e_drugDB_clean.csv`) contiene 152,759 pares fármaco-reacción sobre 1,556 fármacos únicos y 4,251 reacciones MEDDRA únicas. El análisis molecular mediante Morgan fingerprints (ECFP4, radio=2, 1024 bits) y similitud Tanimoto revela

que los fármacos hepatotóxicos forman clústeres de alta similitud estructural ($T > 0.4$), lo cual es consistente con la hipótesis de que la estructura molecular predice parcialmente el perfil de toxicidad. El análisis de componentes principales explica el 9.84 % de la varianza en las dos primeras dimensiones —resultado esperado para vectores binarios de alta dimensión— mientras que el clustering k -means con $k = 5$ identifica arquetipos moleculares farmacológicamente interpretables.

Palabras clave: farmacovigilancia, calidad de datos, TDQM, fingerprints moleculares, similitud Tanimoto, SIDER, PubChem, record linkage, reacciones adversas a medicamentos.

Abstract

Computational pharmacovigilance faces a structural challenge: databases recording adverse drug reactions and those describing the molecular structure of the same drugs are heterogeneous sources maintained by different organizations with incompatible naming conventions. This project builds a complete data quality and preprocessing pipeline integrating SIDER 4.1 —163,206 drug–adverse reaction pairs in MedDRA terminology— with PubChem —1,556 molecular structures in SMILES format— to answer: *Do drugs causing the same type of adverse reaction share molecular substructures?*

The work applies the Total Data Quality Management (TDQM) framework across four phases (Define, Measure, Analyze, Improve) and five quality dimensions: completeness, consistency, accuracy, uniqueness, and validity. Five problems were identified and resolved: (1) 10,447 duplicate records (6.4 %) caused by stereoisomer encoding in STITCH identifiers; (2) semantic heterogeneity quantified via Jaro-Winkler similarity, with 54.1 % of name pairs scoring below 0.50; (3) complete absence of the severity field, recovered through imputation from `meddra_freq.tsv` raising coverage from 0 % to 41.4 %; (4) structural validation of all SMILES strings with RDKit yielding 100 % validity; (5) name normalization modifying 777 of 1,556 unique drug names.

The resulting canonical model contains 152,759 drug–reaction pairs across 1,556 unique drugs and 4,251 unique MedDRA reactions. Molecular analysis using Morgan fingerprints (ECFP4, radius=2, 1024 bits) and Tanimoto similarity reveals that hepatotoxic drugs form high-similarity clusters ($T > 0.4$), consistent with the hypothesis that molecular structure

partially predicts toxicity profiles. Principal component analysis explains 9.84 % of variance in two dimensions —expected for high-dimensional binary vectors— while k -means clustering with $k = 5$ identifies pharmacologically interpretable molecular archetypes.

Keywords: pharmacovigilance, data quality, TDQM, molecular fingerprints, Tanimoto similarity, SIDER, PubChem, record linkage, adverse drug reactions.

Índice general

Resumen Ejecutivo	II
Abstract	IV
1. Marco Teórico de Calidad de Datos	2
1.1. La calidad de datos como problema crítico	2
1.2. Framework TDQM: Total Data Quality Management	3
1.3. Las cinco dimensiones de calidad del proyecto	4
1.3.1. Completitud	4
1.3.2. Consistencia	5
1.3.3. Exactitud	5
1.3.4. Unicidad	6
1.3.5. Validez	6
1.4. Record Linkage y Entity Resolution	7
1.4.1. Similitud Jaro-Winkler	7
1.5. Fusión de datos y resolución de conflictos	8
1.6. Perfilado de datos	9
2. Dominio de Negocio: Farmacovigilancia	10
2.1. ¿Qué es la farmacovigilancia?	10
2.2. El sistema MedDRA y la estandarización terminológica	11

2.3. Señales de farmacovigilancia y el papel de la calidad de datos	12
2.4. Quimioinformática y farmacovigilancia computacional	13
3. Fuentes de Datos	14
3.1. SIDER 4.1	14
3.1.1. Características técnicas	14
3.1.2. Codificación STITCH y origen de duplicados	15
3.2. PubChem	16
3.2.1. Datos extraídos	16
3.3. Heterogeneidad entre fuentes	16
3.4. Proceso de adquisición y principio de inmutabilidad	19
4. Problemáticas de Negocio y Entendimiento	20
4.1. P1: Fármacos sin estructura molecular no pueden analizarse por seguridad .	20
4.2. P2: Nombres inconsistentes entre fuentes causan pérdida de información . . .	21
4.3. P3: Estructuras moleculares incorrectas generan conclusiones erróneas sobre toxicidad	22
4.4. P4: Duplicados inflan señales de seguridad	23
4.5. P5: ¿Es posible predecir reacciones adversas a partir de la estructura molecular?	23
5. Propuestas de Solución	25
5.1. P1 → Integración por PubChem CID (JOIN exacto)	25
5.2. P2 → Record linkage Jaro-Winkler y resolución por prioridad SIDER	26
5.3. P3 → Validación y canonicalización con RDKit	27
5.4. P4 → Deduplicación por clave compuesta	28
5.5. P5 → Morgan Fingerprints + Tanimoto + PCA + k-means	29
5.5.1. Teoría de Morgan Fingerprints (ECFP4)	29
5.5.2. Similitud Tanimoto	30
5.5.3. Análisis de Componentes Principales	30

5.5.4. Clustering k-means	31
6. Perfilado de Datos — Fase Medir	32
6.1. Metodología y herramientas	32
6.2. Estructura del dataset antes de limpieza	33
6.3. Métricas por dimensión de calidad	34
6.4. Análisis de distribuciones	36
6.4.1. Top 20 reacciones adversas más frecuentes	36
6.4.2. Distribución de reacciones por fármaco	37
6.4.3. Completitud por columna	38
6.4.4. Top 20 fármacos por número de reacciones	39
6.5. Métricas de calidad visualizadas	40
6.6. Causas raíz de los problemas identificados	42
7. Limpieza de Datos — Fase Mejorar	43
7.1. Imputación de severity desde meddra_freq.tsv	43
7.2. Validación y canonicalización de SMILES	46
7.3. Normalización de nombres de medicamentos	47
7.4. Análisis de outliers por IQR	48
7.5. Comparación antes vs. después de la limpieza	52
8. Datos Maestros: Modelo Canónico, Record Linkage y Fusión	54
8.1. Fundamentos de Master Data Management	54
8.2. Diseño del modelo canónico	56
8.3. Record Linkage: metodología detallada	57
8.4. Arquitectura de integración	58
9. Preprocesamiento y Análisis Molecular	60
9.1. Análisis sobre SIDER (Fuente Individual — Sección A)	61

9.1.1.	Top 15 reacciones adversas (A1)	61
9.1.2.	Co-ocurrencia de reacciones (A5)	62
9.2.	Análisis sobre PubChem (Fuente Individual — Sección B)	63
9.2.1.	Distribución de peso molecular (B1)	63
9.2.2.	Espacio farmacológico: MW vs logP (B2)	64
9.3.	Análisis cross-source SIDER + PubChem (Sección C)	65
9.3.1.	Propiedades moleculares según categoría de severidad (C3)	65
9.3.2.	TPSA en fármacos con reacciones neurológicas (C9)	66
9.4.	Análisis molecular con RDKit: fingerprints y Tanimoto (Sección D)	67
9.4.1.	Cálculo de Morgan fingerprints	67
9.4.2.	Similitud Tanimoto entre fármacos hepatotóxicos (D1)	68
9.4.3.	Distribución de Tanimoto por grupo de reacción (D2)	69
9.4.4.	PCA de fingerprints moleculares (D3)	70
9.4.5.	Clustering k-means sobre fingerprints (D4)	71
9.5.	Respuesta a la pregunta de investigación	73
10.	Conclusiones	74
10.1.	Conclusiones de calidad de datos	74
10.2.	Conclusiones científicas	75
10.3.	Limitaciones del estudio	76
10.4.	Trabajo futuro	77
10.5.	Reflexión sobre el framework TDQM	77
A.	Diccionario Completo de Variables	83
B.	Ambiente Computacional y Reproducibilidad	87
C.	Fragmentos de Código Esenciales	90

Índice de figuras

6.1. Top 20 reacciones adversas más frecuentes por número de fármacos asociados. La dominancia de síntomas gastrointestinales y cutáneos refleja el sesgo del dataset hacia fármacos de uso sistémico con perfil de toxicidad gastrointestinal conocido.	36
6.2. Distribución de reacciones adversas únicas por fármaco. La distribución es marcadamente asimétrica a la derecha (sesgada positivamente): la mayoría de los fármacos tiene entre 1 y 150 reacciones, pero existe una cola larga de fármacos polifarmacológicos con más de 400 reacciones.	37
6.3. Porcentaje de valores no nulos por columna del modelo canónico. Todas las columnas excepto severity tienen completitud del 100 %, lo que confirma que la integración fue exitosa y que el único problema de completitud es estructural (campo no disponible en la fuente base).	38
6.4. Top 20 fármacos con más reacciones adversas únicas reportadas. La lista está dominada por psicofármacos de amplio espectro (aripiprazol, pregabalina, citalopram), consistente con su mecanismo multitarget sobre el sistema nervioso central.	39
6.5. Métricas de calidad por dimensión antes de la limpieza. La mayoría de las dimensiones están al 100 %, con la excepción crítica de severity (0 %) y la advertencia en exactitud de SMILES por longitud (99.9 %, que corresponde a un único compuesto con SMILES de longitud ≤ 2).	40

7.1.	Distribución de categorías de severidad/frecuencia tras imputación. El 58.6 % permanece como “unknown” (no disponible en meddra_freq.tsv), mientras que el 41.4 % restante muestra un perfil de riesgo dominado por reacciones comunes y post-comercialización.	46
7.2.	Boxplot e histograma de reacciones adversas por fármaco. La línea roja discontinua marca el límite superior por IQR (273 reacciones). Los 94 fármacos por encima del límite son polifarmacológicos con perfiles de RAM ampliamente documentados en la literatura clínica.	51
7.3.	Comparación de completitud en las tres dimensiones intervenidas por la limpieza. La mejora más significativa es la de severity: de 0 % a 41.4 %, un incremento de 41.4 puntos porcentuales. Las otras dos dimensiones ya estaban al 100 % (SMILES válidos) o cerca (nombres normalizados).	52
7.4.	Comparación completa de todas las métricas de calidad antes y después de la limpieza. La única dimensión que muestra mejora es la completitud de severity. Las demás ya estaban al nivel máximo, lo que confirma que la integración por CID fue exitosa en construir un modelo canónico internamente consistente. .	52
8.1.	Arquitectura de integración de datos desde fuentes crudas hasta el modelo canónico limpio. Cada flecha representa un JOIN determinístico por identificador numérico (CID o stitch_flat). El proceso es reproducible: dado el mismo estado de las fuentes, siempre produce el mismo resultado.	59
9.1.	A1 — Top 15 reacciones adversas más reportadas en SIDER 4.1 por número de fármacos asociados. La lista es consistente con la conocida jerarquía de RAM más comunes en medicamentos de uso sistémico: síntomas gastrointestinales (nausea, vómito, diarrea), del sistema nervioso (cefalea, mareo) y dermatológicos (rash, dermatitis). Esta distribución refleja la cobertura del corpus, no la frecuencia real de RAM en la población.	61

- 9.2. A5 — Matriz de co-ocurrencia de las 10 reacciones adversas más frecuentes. Cada celda indica el número de fármacos que presentan simultáneamente ambas reacciones. El par (Nausea, Vomiting) tiene la mayor co-ocurrencia (>900 fármacos), lo que es farmacológicamente esperable dado que ambas comparten mecanismos emetogénicos. La alta co-ocurrencia de síntomas gastrointestinales con reacciones dermatológicas sugiere que los fármacos con acción sistémica tienden a tener perfiles de RAM amplios. 62
- 9.3. B1 — Distribución de peso molecular de los 1,556 fármacos. La distribución es bimodal y sesgada positivamente: el modo principal está alrededor de 300–500 Da (fármacos de síntesis clásicos), con una cola hacia moléculas más grandes (péptidos, macromoléculas). La línea roja discontinua marca el límite de Lipinski ($MW \leq 500$ Da). La media de 500.2 Da indica que el corpus incluye una proporción significativa de fármacos que transgreden la regla de Lipinski en peso molecular. 63
- 9.4. B2 — Espacio farmacológico de Lipinski: peso molecular vs. logP coloreado por número de anillos. Los fármacos que cumplen ambas reglas (cuadrante inferior izquierdo) son la mayoría (69.9%). Los fármacos fuera del espacio de Lipinski tienden a ser péptidos (alto MW, bajo logP) o compuestos lipofílicos (alto logP, bajo MW). El gradiente de color revela que los fármacos con más anillos aromáticos tienden a ser más lipofílicos (mayor logP), consistente con la contribución electrónica de los anillos a la lipofilicidad. 64
- 9.5. C3 — Distribución del número de reacciones adversas por fármaco según la categoría de severidad de la reacción. Los fármacos cuyas reacciones se clasifican como “very_common” tienden a tener más reacciones totales reportadas (mayor mediana), lo que sugiere que los fármacos con muchas RAM también tienden a reportar más reacciones frecuentes —consistente con el perfil de los antipsicóticos atípicos y antiepilépticos del top de outliers. 65

- 9.6. C9 — Distribución del área polar superficial total (TPSA) en fármacos con reacciones neurológicas (azul) vs. otros fármacos (naranja). La línea verde discontinua marca $TPSA = 90 \text{ \AA}^2$, umbral empírico de penetración de la barrera hematoencefálica (BHE). Los fármacos con RAM neurológicas muestran un modo más pronunciado por debajo de $90 \text{ \AA}^2$, consistente con la hipótesis de que estos fármacos penetran la BHE —condición necesaria para causar reacciones del SNC. 66
- 9.7. D1 — Mapa de calor de similitud Tanimoto entre los primeros 20 fármacos con reacciones hepáticas reportadas (hepatic failure, hepatotoxicity y relacionadas). Los bloques de color verde intenso en la diagonal de bloques indican subgrupos de fármacos con alta similitud molecular ($T > 0.4$). Esto es evidencia directa de que dentro del grupo de fármacos hepatotóxicos existen clústeres estructuralmente homogéneos, consistente con H_1 68
- 9.8. D2 — Distribución de similitud Tanimoto entre pares de fármacos del mismo grupo de reacción (top 5 reacciones adversas). La línea roja discontinua marca el umbral convencional de similitud significativa ($T = 0.4$). La mayoría de las distribuciones tienen su modo por debajo de 0.4, lo que indica que dentro de cada grupo de RAM la diversidad molecular es alta. Sin embargo, la presencia de valores $T > 0.4$ en todos los grupos confirma la existencia de subgrupos estructuralmente similares dentro de cada categoría de RAM. 69
- 9.9. D3 — Proyección PCA de los 1,556 vectores de fingerprint Morgan (1,024 dimensiones) en dos componentes principales. PC1 explica el 6.08 % de la varianza; PC2, el 3.76 %; conjuntamente el 9.84 %. El color indica el número de reacciones adversas del fármaco. La distribución no es aleatoria: existen regiones del espacio PCA con mayor densidad de fármacos con muchas RAM, sugiriendo que la estructura molecular y el número de RAM están parcialmente correlacionados. 70

- 9.10. D4 — Clustering k-means ($k = 5$) sobre los 1,556 fingerprints moleculares visualizado en el espacio PCA. Los cinco clusters representan arquetipos moleculares farmacológicamente interpretables. La separación no es perfecta en el espacio 2D (reflejo de la baja varianza explicada), pero los centroides de los clusters son estadísticamente distintos en el espacio original de 1,024 dimensiones. 71

Índice de cuadros

3.1. Heterogeneidad técnica entre fuentes de datos	16
3.2. Muestra de heterogeneidad semántica: nombre SIDER vs. nombre IUPAC (PubChem)	18
6.1. Estructura y estadísticas del modelo canónico antes de limpieza	34
6.2. Métricas de calidad antes de limpieza (calculadas sobre 152,759 filas)	35
6.3. Análisis de causas raíz de problemas de calidad detectados en el perfilado	42
7.1. Mapeo de etiquetas cualitativas a categorías MedDRA de frecuencia	44
7.2. Distribución de severity tras imputación	45
7.3. Top 5 fármacos outlier por número de reacciones adversas únicas	50
7.4. Resumen comparativo cuantitativo: antes vs. después de limpieza	53
8.1. Diccionario de variables del modelo canónico <code>e_drugDB_clean.csv</code>	56
8.2. Resultados del record linkage por categoría de similitud Jaro-Winkler	57
9.1. Silhouette scores para distintos valores de k en k-means	72
A.1. Diccionario de variables del modelo canónico <code>e_drugDB_clean.csv</code>	83
B.1. Versiones de bibliotecas del ambiente computacional	88

Capítulo 1

Marco Teórico de Calidad de Datos

1.1. La calidad de datos como problema crítico

Para el lector no especialista

Los datos son el combustible de cualquier análisis. Si los datos están incompletos, duplicados o son inconsistentes entre fuentes, las conclusiones que se derivan de ellos pueden ser erróneas —o directamente peligrosas. En el contexto de medicamentos, datos de mala calidad pueden ocultar señales de seguridad que deberían haber retirado un fármaco del mercado.

La gestión de la calidad de datos es reconocida como una de las capacidades críticas de las organizaciones modernas impulsadas por datos. [Gartner, Inc. \(2021\)](#) estima que la mala calidad de datos cuesta a las organizaciones un promedio de 12.9 millones de dólares anuales en decisiones sub-óptimas, retrabajos y pérdida de oportunidades. En el sector sanitario, este costo adquiere una dimensión adicional que no puede expresarse en términos monetarios: las decisiones basadas en datos de baja calidad pueden resultar en daño directo a pacientes.

El ejemplo más citado en la historia de la farmacovigilancia es el caso del *rofecoxib* (Vioxx), retirado del mercado en 2004 por su asociación con infarto de miocardio. Las señales de seguridad estuvieron presentes en los datos desde los ensayos clínicos, pero la fragmen-

tación, duplicación e inconsistencia de los reportes retrasó su identificación ([Almenoff et al. 2007](#)). Un sistema robusto de calidad de datos habría acelerado la detección de esa señal, potencialmente evitando decenas de miles de eventos cardiovasculares.

Calidad de datos (según DAMA-DMBOK 2.0)

La calidad de datos es el grado en que los datos satisfacen los requisitos del uso previsto en las operaciones, toma de decisiones y planificación. La calidad no es una propiedad absoluta del dato, sino relativa al contexto de uso ([DAMA International 2017](#)).

1.2. Framework TDQM: Total Data Quality Management

El framework TDQM fue propuesto por [Wang and Strong \(1996\)](#) en su artículo seminal “Beyond Accuracy: What Data Quality Means to Data Consumers”, publicado en *Journal of Management Information Systems*. Este trabajo estableció que la calidad de datos es multidimensional —no se reduce a la exactitud— y que debe gestionarse de forma sistemática, de manera análoga a la gestión de la calidad en manufactura (norma ISO 9001).

TDQM organiza la mejora de la calidad en cuatro fases iterativas que forman un ciclo de mejora continua:

1. **Definir** (*Define*): Identificar las dimensiones de calidad relevantes para el problema de negocio, establecer métricas medibles y umbrales de aceptación. En este proyecto: cinco dimensiones (Sección 1.3) con umbrales justificados por guías regulatorias de farmacovigilancia.
2. **Medir** (*Measure*): Perfilar los datos en su estado actual, antes de cualquier intervención. El perfilado cuantifica la brecha entre la calidad actual y la requerida. En este proyecto: ejecutado con `ydata-profiling` y métricas ad hoc sobre el modelo canónico (Capítulo 6).

3. **Analizar** (*Analyze*): Identificar las causas raíz de los problemas de calidad detectados.

La distinción entre síntoma y causa raíz es fundamental: duplicados (síntoma) cuya causa es la codificación de estereoisómeros en identificadores STITCH (causa raíz). Sin esta distinción, la solución es cosmética.

4. **Mejorar** (*Improve*): Implementar las correcciones y transformaciones necesarias. En este proyecto: imputación de *severity*, validación y canonicalización de SMILES, normalización de nombres, deduplicación (Capítulo 7).

El ciclo es iterativo: tras la fase de Mejorar, se vuelve a Medir para verificar que la calidad efectivamente mejoró y cuantificar la ganancia. Este proyecto materializa este ciclo con un perfilado antes y después de la limpieza (Capítulo 6), permitiendo comparar métricas cuantitativamente.

1.3. Las cinco dimensiones de calidad del proyecto

La literatura establece más de veinte dimensiones de calidad de datos (Wang and Strong 1996; DAMA International 2017). Para este proyecto se seleccionaron cinco, directamente mapeadas a los problemas de negocio identificados (Capítulo 4).

1.3.1. Completitud

Completitud

Grado en que todos los valores requeridos están presentes en el dataset. Se mide como la proporción de valores no nulos sobre el total esperado:

$$C_j = \frac{n_{j,\text{no_nulo}}}{n_{\text{total}}} \times 100 \%$$

donde j indexa la columna analizada.

En farmacovigilancia, la incompletitud tiene consecuencias directas en la priorización de señales. Si el campo *severity* (frecuencia de la reacción adversa) está ausente, es imposible distinguir una reacción que afecta a 1 de cada 10 pacientes de una que afecta a 1 de cada 10,000. El umbral mínimo aceptable para columnas críticas se establece en 95 %, siguiendo las guías de buenas prácticas de farmacovigilancia de la Agencia Europea de Medicamentos (European Medicines Agency 2017).

1.3.2. Consistencia

Consistencia

Grado en que los datos de distintas fuentes o representaciones son coherentes entre sí. Aquí se mide como la similitud semántica entre el nombre del fármaco en SIDER (nombre INN/comercial) y en PUBCHEM (nombre IUPAC):

$$\text{Consistencia}_i = \text{JaroWinkler}(\text{nombre_SIDER}_i, \text{nombre_IUPAC}_i)$$

La inconsistencia de nombres entre fuentes es el principal obstáculo para la integración. Un mismo compuesto puede llamarse “Aspirin” en SIDER y “2-(acetyloxy)benzoic acid” en PUBCHEM: mismo fármaco, representaciones completamente distintas. Sin un identificador canónico (PubChem CID), sería imposible enlazar ambas fuentes con precisión.

1.3.3. Exactitud

Exactitud

Grado en que los datos reflejan correctamente la realidad que representan. Para estructuras moleculares, se verifica mediante análisis químico-computacional: un SMILES es exacto si (a) es sintácticamente válido, (b) representa una molécula químicamente posible (valencias correctas, aromaticidad consistente), y (c) corresponde al compuesto esperado según su identificador.

La exactitud de los SMILES es crítica porque toda la sección de análisis molecular

(Capítulo 9) se construye sobre la estructura química. Un SMILES incorrecto generaría un fingerprint erróneo, corrompiendo todos los cálculos de similitud Tanimoto y los modelos de clustering.

1.3.4. Unicidad

Unicidad

Grado en que cada entidad real está representada una sola vez en el dataset. Se mide como:

$$U = \left(1 - \frac{n_{\text{duplicados}}}{n_{\text{total}}}\right) \times 100 \%$$

Los duplicados en datos de farmacovigilancia tienen un efecto perniciosos particularmente grave: inflan artificialmente la frecuencia de señales de seguridad. Si el par (Aspirina, Nausea) aparece tres veces en la base de datos por razones técnicas (no porque tres estudios distintos lo hayan reportado), el sistema sobreestimaré la frecuencia de esa reacción adversa, potencialmente desencadenando alertas regulatorias innecesarias o desviando recursos de vigilancia.

1.3.5. Validez

Validez

Grado en que los datos satisfacen las reglas de negocio y estándares del dominio. En este proyecto: (a) los términos de reacciones adversas deben pertenecer a la terminología MedDRA PT (*Preferred Term*); (b) los SMILES deben ser parseables por RDKit con sanitización química completa; (c) los identificadores de frecuencia de reacciones adversas deben pertenecer al vocabulario controlado MedDRA de frecuencias.

1.4. Record Linkage y Entity Resolution

El record linkage es el proceso de identificar registros que se refieren a la misma entidad real en fuentes de datos distintas (Fellegi and Sunter 1969). Es uno de los problemas más estudiados en gestión de datos, con aplicaciones que van desde la fusión de censos poblacionales hasta la integración de historias clínicas electrónicas.

Para el lector no especialista

Imagina que tienes dos listas de contactos telefónicos: una dice “Juan García” y la otra dice “J. García Martínez”. Probablemente es la misma persona, pero ningún sistema automático lo sabe con certeza. El record linkage es el proceso de tomar decisiones sobre cuáles registros son la misma entidad, usando métricas de similitud entre sus atributos.

El modelo probabilístico de Fellegi and Sunter (1969) formaliza esta decisión como un test de hipótesis: dado un par de registros (a, b) , se calcula un cociente de verosimilitud R que determina si el par debe clasificarse como coincidencia (*match*), no coincidencia (*non-match*), o caso dudoso que requiere revisión manual.

1.4.1. Similitud Jaro-Winkler

La métrica Jaro (Jaro 1989) fue desarrollada específicamente para comparar nombres de personas en registros del censo de Estados Unidos. Su extensión Jaro-Winkler (Winkler 1990) da mayor peso al prefijo compartido, lo que la hace especialmente apropiada para nombres de medicamentos, donde el prefijo suele ser la parte más discriminante (“preg-” en pregabalina, “arip-” en aripiprazol).

La similitud Jaro entre dos cadenas s_1 y s_2 se define como:

$$d_J(s_1, s_2) = \begin{cases} 0 & \text{si } m = 0 \\ \frac{1}{3} \left(\frac{m}{|s_1|} + \frac{m}{|s_2|} + \frac{m - t/2}{m} \right) & \text{en otro caso} \end{cases}$$

donde m es el número de caracteres coincidentes (dentro de una ventana de $\lfloor \max(|s_1|, |s_2|)/2 \rfloor - 1$) y t es el número de transposiciones. La similitud Jaro-Winkler añade un ajuste para el prefijo:

$$d_{JW}(s_1, s_2) = d_J + \ell \cdot p \cdot (1 - d_J)$$

donde ℓ es la longitud del prefijo común (máximo 4 caracteres) y $p = 0.1$ es el factor de escala estándar.

Decisión metodológica: Jaro-Winkler sobre Levenshtein para comparación de nombres de fármacos

La distancia de Levenshtein cuenta el número mínimo de ediciones (inserción, eliminación, sustitución) para transformar una cadena en otra. Para nombres largos como “2-(acetyloxy)benzoic acid” vs “Aspirin”, la distancia Levenshtein es muy alta aunque el significado sea idéntico. Jaro-Winkler, al normalizar por longitud y dar peso al prefijo, produce puntajes más intuitivos para nombres de sustancias: “acetylcholine” vs “2-acetyloxyethyl(trimethyl)azanium” obtiene $d_{JW} = 0.663$, correctamente clasificado como similitud media. Levenshtein daría una distancia absoluta de 35, sin contexto de lo que eso significa para cadenas de estas longitudes.

1.5. Fusión de datos y resolución de conflictos

La fusión de datos (*data fusion* o *data consolidation*) es el proceso de combinar información de múltiples fuentes en una representación unificada, resolviendo los conflictos que surgen cuando las fuentes discrepan (Lenzerini 2002).

Las estrategias principales de resolución de conflictos son:

- **Trust-One-Source:** Se designa una fuente como autoritativa para cada atributo. Simple y eficiente; requiere conocimiento de cuál fuente es más confiable para cada campo.
- **Voting:** La mayoría de las fuentes determina el valor correcto. Requiere tres o más

fuentes.

- **Seniority**: Se prefiere la fuente más reciente o más especializada según el atributo.
- **Metadata-based**: La proveniencia (fuente, fecha de actualización, score de confianza) determina la prioridad.

En este proyecto se aplica **Trust-One-Source** con lógica de cascada: SIDER es la fuente autoritativa para el nombre del fármaco, y PUBCHEM para la estructura molecular. La justificación se desarrolla en la Sección 5.2.

1.6. Perfilado de datos

El perfilado de datos (*data profiling*) es el proceso de examinación sistemática de un dataset para recopilar estadísticas descriptivas, identificar patrones y detectar anomalías, *sin modificar los datos* (Lloyd et al. 2019). Es la fase de Medir del ciclo TDQM y debe ejecutarse antes de cualquier limpieza.

En este proyecto se utilizó **ydata-profiling** (antes denominado **pandas-profiling**), que genera automáticamente reportes HTML interactivos con estadísticas univariadas y bivariadas, análisis de correlaciones, detección de valores faltantes y alertas de calidad. Dado que el dataset completo tiene 152,759 filas, se utilizó una muestra estratificada de 20,000 filas para el reporte HTML, mientras que las métricas cuantitativas se calcularon sobre el dataset completo (ver Capítulo 6).

Capítulo 2

Dominio de Negocio: Farmacovigilancia

2.1. ¿Qué es la farmacovigilancia?

Para el lector no especialista

Cuando un medicamento llega al mercado, ha pasado por ensayos clínicos con varios miles de pacientes. Pero una vez que millones de personas lo toman en condiciones reales —distinta edad, distintas enfermedades simultáneas, distintos otros medicamentos— pueden aparecer reacciones adversas que no se detectaron en los ensayos. La farmacovigilancia es el sistema de vigilancia post-comercialización que monitorea estos eventos para proteger a los pacientes.

La Organización Mundial de la Salud define la farmacovigilancia como “la ciencia y actividades relacionadas con la detección, evaluación, comprensión y prevención de efectos adversos o cualquier otro problema relacionado con los medicamentos” ([World Health Organization 2002](#)). Es una disciplina esencial del ciclo de vida de los medicamentos: no termina con la aprobación regulatoria, sino que continúa indefinidamente mientras el fármaco esté en uso.

La escala del problema justifica plenamente la inversión en infraestructura de datos de calidad: la OMS estima que las reacciones adversas a medicamentos (RAM) causan entre el 5 % y el 10 % de todos los ingresos hospitalarios, y son la cuarta a sexta causa de muerte en países industrializados ([World Health Organization 2002](#)). En términos absolutos, se estima que más de 100,000 muertes anuales en Estados Unidos son atribuibles a RAM.

2.2. El sistema MedDRA y la estandarización terminológica

MedDRA (Medical Dictionary for Regulatory Activities)

Terminología médica internacional desarrollada bajo el auspicio de la Conferencia Internacional de Armonización (ICH). Es el estándar mandatorio para la comunicación regulatoria de datos de seguridad con la FDA, EMA, PMDA y otras agencias reguladoras del mundo.

MEDDRA organiza los términos médicos en una jerarquía de cinco niveles:

Nivel	Nombre	Ejemplo
1 (más genérico)	SOC — System Organ Class	<i>Gastrointestinal disorders</i>
2	HLGT — High Level Group Term	<i>Nausea and vomiting symptoms</i>
3	HLT — High Level Term	<i>Nausea and vomiting</i>
4	PT — Preferred Term	<i>Nausea</i>
5 (más específico)	LLT — Lowest Level Term	<i>Feeling sick</i>

Decisión metodológica: Uso exclusivo de nivel PT (Preferred Term)

Se utiliza exclusivamente el nivel PT por tres razones: (1) Es el nivel de mayor precisión clínica con granularidad manejable —4,251 términos únicos en este dataset, frente a los más de 70,000 LLT que fragmentarían el análisis; (2) Es el nivel estándar para análisis de señales en farmacovigilancia ([Lindquist 2008](#)); (3) Los niveles SOC y HLGT son demasiado genéricos para identificar subestructuras moleculares específicas: la señal de “Gastrointestinal disorders” es compartida por casi todos los medicamentos, mientras que “Nausea” permite distinguir perfiles de toxicidad gastrointestinal con mayor especificidad.

2.3. Señales de farmacovigilancia y el papel de la calidad de datos

Una señal de farmacovigilancia es “información comunicada de una posible relación causal entre un evento adverso y un medicamento, siendo la relación desconocida o documentada incompletamente” ([World Health Organization 2002](#)). La detección de señales requiere datos de alta calidad porque:

- **Duplicados inflan la frecuencia:** si el par (fármaco, reacción) aparece múltiples veces, los algoritmos de detección de señales (disproportionality analysis, reporting odds ratio) sobreestiman la fuerza de la asociación.
- **Incompletitud oculta señales:** si el campo de severidad está ausente, es imposible priorizar las señales más graves. Una reacción “very rare” ($< 1/10,000$) que causa fallo orgánico es más urgente que una reacción “very common” ($\geq 1/10$) que causa cefalea leve.
- **Inconsistencias fragmentan señales:** si el mismo fármaco aparece bajo múltiples

nombres, las señales se diluyen al no acumularse bajo un identificador común.

2.4. Quimioinformática y farmacovigilancia computacional

La quimioinformática es la disciplina que aplica métodos computacionales e informáticos al análisis de datos químicos ([Brown et al. 2019](#)). La intersección con farmacovigilancia genera la farmacovigilancia computacional: el uso de representaciones moleculares para predecir, explicar y priorizar señales de seguridad.

La premisa fundamental que justifica la Sección D del análisis es la hipótesis de similitud molecular: moléculas estructuralmente similares tienden a compartir actividades biológicas y, por extensión, perfiles de toxicidad ([Maggiora et al. 2014](#)). Esta hipótesis, denominada “molecular similarity principle” en la literatura de química medicinal, tiene un corolario en farmacovigilancia:

Hallazgo clave: Hipótesis de investigación

Si la estructura molecular predice la actividad biológica (premisa del QSAR), entonces los fármacos que comparten subestructuras moleculares deberían compartir mecanismos de acción y, parcialmente, perfiles de reacciones adversas. Esta es la hipótesis central (H_1) que este proyecto pone a prueba mediante fingerprints moleculares y análisis de similitud Tanimoto.

La referencia canónica para fingerprints en quimioinformática es [Rogers and Hahn \(2010\)](#), cuyo artículo “Extended-Connectivity Fingerprints” describe el algoritmo ECFP (ECFP4 con radio 2 = diámetro 4), adoptado como estándar de facto en virtual screening, QSAR y farmacovigilancia computacional. Un trabajo reciente de relevancia directa es [Maciejewski et al. \(2021\)](#), que demuestra mediante análisis de redes de similitud molecular que los fármacos con perfiles similares de efectos adversos muestran mayor similitud estructural de lo esperado por azar, validando la hipótesis de investigación de este proyecto.

Capítulo 3

Fuentes de Datos

3.1. SIDER 4.1

SIDER (*Side Effect Resource*) es una base de datos pública desarrollada por el grupo del Dr. Peer Bork en el EMBL-European Bioinformatics Institute ([Kuhn et al. 2016](#)). Contiene información de efectos secundarios de fármacos aprobados, extraída mediante procesamiento de lenguaje natural (NLP) de las etiquetas regulatorias de medicamentos (FDA *drug labels*, EMA *Summary of Product Characteristics*).

3.1.1. Características técnicas

- **Formato:** TSV (valores separados por tabulador), UTF-8
- **Identificadores:** STITCH IDs (derivados de PubChem CIDs con un offset para codificar estereoisómeros)
- **Terminología:** MEDDRA PT y SOC, con códigos UMLS
- **Cobertura:** 1,430 fármacos con nombre SIDER; 4,251 efectos adversos únicos (PT); 163,206 pares fármaco-reacción a nivel PT
- **Archivos utilizados:**

- `sider_se_pt.csv`: 163,206 filas con columnas `stitch_flat`, `pubchem_cid`, `umls_meddra`, `side_effect_name`
- `sider_drug_names.csv`: 1,430 filas con `stitch_flat` y `drug_name` (nombre INN/comercial)
- `meddra_freq.tsv`: Información de frecuencia/severidad (fuente para imputación)

■ **Fecha de última actualización:** 2015 (base de datos congelada)

Limitación / Consideración: Obsolescencia de SIDER 4.1

SIDER no ha sido actualizado desde 2015. Esto implica que los fármacos aprobados entre 2015 y 2026 —incluyendo la mayoría de los agentes inmunooncológicos, terapias CAR-T y fármacos de ARNm— no están representados. Los hallazgos de este proyecto son válidos para el corpus de fármacos pre-2015 y deben interpretarse con esta limitación temporal.

3.1.2. Codificación STITCH y origen de duplicados

SIDER utiliza identificadores STITCH, que son una extensión de los PubChem CIDs diseñada para distinguir estereoisómeros. La codificación es:

- `stitch_flat`: CID del compuesto sin información estereoquímica (ej., CID000002244)
- `stitch_stereo`: CID con prefijo para la estereoisomería (positivo o negativo)

Esta codificación genera el principal problema de unicidad del dataset: el mismo par (fármaco, reacción) puede aparecer bajo múltiples `stitch_stereo` IDs para el mismo `pubchem_cid`, resultando en registros que son técnicamente distintos (diferente estereoisómero) pero que para el análisis a nivel de CID base son duplicados funcionales.

3.2. PubChem

PUBCHEM es el repositorio de información química más grande del mundo, mantenido por el NCBI (National Center for Biotechnology Information) de los Institutos Nacionales de Salud de Estados Unidos ([Kim et al. 2023](#)). A 2023, contiene más de 111 millones de compuestos únicos, 300 millones de sustancias y 290 millones de actividades biológicas.

3.2.1. Datos extraídos

Para este proyecto se obtuvo, para cada uno de los 1,556 CIDs únicos presentes en SIDER:

- **SMILES canónico:** cadena de texto que describe la estructura molecular en el lenguaje SMILES ([Weininger 1988](#))
- **Nombre IUPAC:** nombre sistemático generado algorítmicamente por el software de nomenclatura de PUBCHEM

La cobertura fue del 100 %: los 1,556 CIDs de SIDER tienen registro en PUBCHEM. Esta cobertura completa se debe a que SIDER fue construido originalmente a partir de datos de PUBCHEM, garantizando la existencia de los CIDs en el repositorio fuente.

3.3. Heterogeneidad entre fuentes

La integración de SIDER y PUBCHEM presenta heterogeneidades en tres dimensiones:

Cuadro 3.1: Heterogeneidad técnica entre fuentes de datos

Aspecto	SIDER 4.1	PubChem
Formato de archivo	TSV (tab-separated)	JSON via REST API / CSV via FTP

Continúa en la página siguiente

(Continuación de la Tabla 3.1)

Aspecto	SIDER 4.1	PubChem
Identificador principal	STITCH ID (CID + offset estéreo)	PubChem CID (entero)
Nombre del compuesto	INN / nombre comercial (inglés)	Nombre IUPAC generado algorítmicamente
Estructura molecular	Ausente	SMILES canónico
Reacciones adversas	Términos MedDRA PT/SOC + UMLS	Ausente
Severidad	Parcial (archivo separado)	Ausente
Cobertura temporal	1950-2015	Continua
Licencia	CC BY-NC 4.0	Dominio público
Actualización	Congelado (2015)	Diaria

La Tabla 3.2 ilustra la heterogeneidad semántica con ejemplos reales del dataset:

Cuadro 3.2: Muestra de heterogeneidad semántica: nombre SIDER vs. nombre IUPAC (PubChem)

Nombre SIDER	Nombre IUPAC (PubChem)	d_{JW}	Categoría
carnitine	(3R)-3-hydroxy-4-(trimethylazaniumyl)butanoate	0.427	Baja
leucovorin	(2S)-2-[[4-[(2-amino-5-formyl-...]amino]	0.493	Baja
PGE2	(Z)-7-[(1R,2R,3R)-3-hydroxy-...	0.341	Baja
gamma-aminobutyric	4-aminobutanoic acid	0.617	Media
5-aminolevulinic	5-amino-4-oxopentanoic acid	0.676	Media
acetylcholine	2-acetyloxyethyl(trimethyl)azanium	0.663	Media
acetate	acetate	1.000	Alta
calcium	calcium(2+)	0.927	Alta

Los resultados del record linkage revelan que la heterogeneidad semántica es la norma, no la excepción: el 54.1 % de los pares tienen $d_{JW} < 0.50$ (baja similitud), mientras que solo el 2.4 % tienen nombres prácticamente idénticos ($d_{JW} \geq 0.85$). La similitud Jaro-Winkler promedio es $\bar{d}_{JW} = 0.495$, justo en el umbral de lo que se considera “coincidencia parcial”. Este hallazgo cuantifica la necesidad del identificador numérico (CID) como ancla del join: sin él, más de la mitad de los registros quedarían sin enlazar.

3.4. Proceso de adquisición y principio de inmutabilidad

Los datos crudos se almacenan en `datos/raw/` sin ninguna modificación. Este principio — denominado *raw data immutability* en las mejores prácticas de ingeniería de datos— garantiza que cualquier análisis puede ser reproducido desde la fuente original, y que los errores en el procesamiento no contaminan el dato original.

```
1  # Carga de fuentes crudas (sin modificación)
2  se    = pd.read_csv(os.path.join(RAW, "sider_se_pt.csv"))
3  drug  = pd.read_csv(os.path.join(RAW, "sider_drug_names.csv"))
4  smi    = pd.read_csv(os.path.join(RAW, "pubchem_smiles.csv"))
5
6  print(f"sider_se_pt      : {len(se):>8,} filas | "
7        f"{se['pubchem_cid'].unique():,} farmacos | "
8        f"{se['side_effect_name'].unique():,} reacciones")
9  print(f"sider_drug_names: {len(drug):>8,} filas | "
10       f"{drug['stitch_flat'].unique():,} farmacos unicos")
11 print(f"pubchem_smiles   : {len(smi):>8,} filas | "
12       f"{smi['pubchem_cid'].unique():,} CIDs unicos")
```

Listing 3.1: Carga de las tres fuentes crudas desde `fusion.py`

La ejecución de este bloque produce:

```
sider_se_pt      : 163,206 filas | 1,556 fármacos | 4,251 reacciones
sider_drug_names:  1,430 filas | 1,430 fármacos únicos
pubchem_smiles   :  1,556 filas | 1,556 CIDs únicos
```

Capítulo 4

Problemáticas de Negocio y Entendimiento

Este capítulo presenta las cinco problemáticas de negocio identificadas, cada una formulada en dos niveles: el lenguaje de negocio (para el responsable de farmacovigilancia) y el lenguaje técnico (para el data scientist). Para cada problemática se especifica la dimensión de calidad afectada, su impacto cuantificado y las consecuencias de no resolverla.

4.1. P1: Fármacos sin estructura molecular no pueden analizarse por seguridad

Enunciado de negocio: Queremos estudiar qué características estructurales comparten los fármacos que causan los mismos tipos de reacciones adversas. Si un fármaco no tiene su estructura molecular disponible en formato computacional, queda automáticamente excluido del análisis. Esto no solo reduce el tamaño de la muestra, sino que puede introducir sesgo sistemático si los fármacos sin estructura son sistemáticamente distintos.

Enunciado técnico: La ausencia de un SMILES válido para un `pubchem_cid` impide el cálculo de Morgan fingerprints, y por ende excluye el fármaco de todos los análisis de

similitud molecular (Sección D). Si la exclusión no es aleatoria —por ejemplo, si los fármacos más antiguos o más complejos estructuralmente tienen menor cobertura— se introduce un sesgo de selección que invalida la generalización de los hallazgos.

Dimensión afectada: Completitud (columna `smiles`).

Impacto cuantificado: Antes de la integración con PUBCHEM, 0 % de los registros tenían SMILES (campo no disponible en SIDER). Tras la integración por CID, se logró 100 % de cobertura para los 1,556 CIDs presentes en SIDER.

Consecuencia si no se resuelve: Imposibilidad total del análisis molecular. El objetivo científico del proyecto —responder si los fármacos con la misma RAM comparten subestructuras— requiere estructuras moleculares.

4.2. P2: Nombres inconsistentes entre fuentes causan pérdida de información

Enunciado de negocio: El mismo medicamento se llama de formas muy distintas en SIDER y PUBCHEM. Si intentamos unir las dos bases de datos usando el nombre del medicamento como clave, fallaríamos en más de la mitad de los casos. Esto significa que medicamentos perfectamente documentados quedarían fuera del análisis, no porque les falten datos, sino porque sus datos están en bases distintas con nombres incompatibles.

Enunciado técnico: La heterogeneidad semántica entre nombres INN/comerciales (SIDER) y nombres IUPAC (PUBCHEM) genera un problema de entity resolution. La métrica cuantificada mediante Jaro-Winkler muestra que el 54.1 % de los pares tiene $d_{JW} < 0.50$, lo que descarta un join por nombre incluso con fuzzy matching de umbral alto. La solución es usar el PubChem CID como clave de join exacto (ver Sección 5.2).

Dimensión afectada: Consistencia.

Impacto cuantificado: De 1,556 pares (`drug_name`, `iupac_name`), 841 (54.1 %) tienen similitud baja; 678 (43.6 %) media; 37 (2.4 %) alta. Similitud promedio: $\bar{d}_{JW} = 0.495$.

Consecuencia si no se resuelve: Un join por nombre con umbral $d_{JW} \geq 0.85$ capturaría solo el 2.4 % de los fármacos. El análisis quedaría restringido a 37 fármacos con nombres casi idénticos entre fuentes (inorgánicos simples como “acetate”, “calcium”), completamente no representativo.

4.3. P3: Estructuras moleculares incorrectas generan conclusiones erróneas sobre toxicidad

Enunciado de negocio: Si la estructura química de un medicamento está mal representada en nuestra base de datos, todos los cálculos de similitud molecular basados en ella serán incorrectos. Es como calcular la huella digital de alguien usando los dedos equivocados: obtendrás una huella, pero no la correcta.

Enunciado técnico: Un string SMILES puede ser (a) sintácticamente inválido (no parseable), (b) sintácticamente válido pero con valencias incorrectas o aromaticidad inconsistente (pasa el parser pero falla la sanitización química), o (c) correcto como molécula pero no canónico (múltiples representaciones válidas de la misma molécula generan fingerprints distintos). Los tres casos requieren tratamientos distintos con RDKit.

Dimensión afectada: Exactitud.

Impacto cuantificado: Validación con RDKit (`Chem.MolFromSmiles()` + `Chem.SanitizeMol()`) 100 % de los 1,556 SMILES son válidos. No obstante, la canonicalización es necesaria para garantizar representación única.

Consecuencia si no se resuelve: Fingerprints inconsistentes para el mismo compuesto generarían similitudes Tanimoto incorrectas, corrompiendo el heatmap D1, la distribución D2, el PCA D3 y los clusters D4.

4.4. P4: Duplicados inflan señales de seguridad

Enunciado de negocio: En la base de datos de efectos adversos, el mismo medicamento causando la misma reacción aparece múltiples veces. Esto no es porque muchos estudios distintos lo hayan reportado de forma independiente —lo cual sería información valiosa— sino por un artefacto técnico de la codificación de los identificadores.

Enunciado técnico: Los STITCH IDs de SIDER diferencian estereoisómeros mediante un offset al PubChem CID. El fármaco “leucovorin” tiene múltiples STITCH IDs correspondientes a distintos estereoisómeros ((2*S*)-leucovorin, (6*S*)-leucovorin, etc.). Para el análisis a nivel de CID base —que es el nivel al que se tienen estructuras en PUBCHEM— estos registros son duplicados del mismo par (fármaco, reacción), pues todos se mapean al mismo CID.

Dimensión afectada: Unicidad.

Impacto cuantificado: 163,206 pares crudos $\rightarrow$ 152,759 tras deduplicación por (drug_id, adverse_reaction). Duplicados eliminados: **10,447** (6.4 %).

Consecuencia si no se resuelve: Sobreestimación de la frecuencia de señales. Los algoritmos de disproportionality analysis (ROR, PRR) producirían valores inflados, generando falsos positivos en la detección de señales de seguridad.

4.5. P5: ¿Es posible predecir reacciones adversas a partir de la estructura molecular?

Enunciado de negocio: La pregunta de fondo de todo el proyecto: ¿podemos usar la “forma” química de un medicamento para predecir qué tipo de efectos secundarios tendrá? Si la respuesta es sí, podríamos identificar preventivamente el perfil de riesgo de nuevos compuestos antes de que lleguen al mercado.

Enunciado técnico: La hipótesis se formula como:

$$H_0 : T_{\text{intra-grupo}}(F, \text{RAM}) = T_{\text{inter-grupo}}(F, \text{RAM}) \quad (4.1)$$

$$H_1 : T_{\text{intra-grupo}}(F, \text{RAM}) > T_{\text{inter-grupo}}(F, \text{RAM}) \quad (4.2)$$

donde $T_{\text{intra-grupo}}$ es la similitud Tanimoto promedio entre pares de fármacos que comparten la misma RAM, y $T_{\text{inter-grupo}}$ es la similitud promedio entre fármacos de distintos grupos de RAM. Si H_1 es verdadera, los fármacos con la misma RAM son molecularmente más similares entre sí que con fármacos de diferentes RAM.

Dimensión afectada: Validez (¿son los datos de estructura molecular válidos como predictores del perfil de toxicidad?).

Tipo de análisis: Predictivo / exploratorio. No se realiza un test de hipótesis formal (el tamaño del subgrupo por RAM varía enormemente y el poder estadístico es heterogéneo), sino un análisis exploratorio con fingerprints, PCA y k -means que aporta evidencia circunstancial.

Capítulo 5

Propuestas de Solución

5.1. P1 $\rightarrow$ Integración por PubChem CID (JOIN exacto)

La solución a la incompletitud de estructuras moleculares es la integración con PUBCHEM usando el PubChem CID como clave de join exacto. Esta decisión es posible porque SIDER incluye el CID en cada registro, lo que convierte el problema de entity resolution en un simple equijoin.

Decisión metodológica: JOIN exacto por CID sobre fuzzy matching por nombre

Un join por nombre requeriría definir un umbral de similitud, tratar casos ambiguos y gestionar falsos positivos (dos fármacos distintos con nombres similares, como “nor-triptyline” y “triptyline”). El join por CID es determinístico, sin falsos positivos posibles, y ejecuta en tiempo $O(n)$ con hashing. Además, el CID es canónico: PUBCHEM garantiza que cada compuesto único tiene exactamente un CID.

```
1 # JOIN principal: SIDER + nombres SIDER + SMILES PubChem
2 merged = (
3     se                                     # 163,206 filas
4     .merge(drug, on="stitch_flat", how="left") # agrega drug_name
```



```
5         .merge(smi, on="pubchem_cid", how="left") # agrega smiles + iupac
6     )
7     # Resultado: 163,206 filas con todas las columnas de las 3 fuentes
```

Listing 5.1: Fusión de fuentes por PubChem CID desde fusion.py

5.2. P2 → Record linkage Jaro-Winkler y resolución por prioridad SIDER

Para resolver la inconsistencia de nombres se aplica el siguiente pipeline:

1. **Cuantificación de la heterogeneidad:** Calcular d_{JW} para todos los pares (drug_name, iupac_name) usando la librería `recordlinkage` con comparación tipo `jarowinkler`.
2. **Categorización:** Clasificar cada par en tres categorías según d_{JW} : alta (≥ 0.85), media ($[0.50, 0.85)$), baja (< 0.50).
3. **Resolución:** Para el campo `name` del modelo canónico, aplicar la regla de prioridad SIDER > IUPAC > “Desconocido”.

```
1  # Configurar comparador de record linkage
2  indexer = recordlinkage.Index()
3  indexer.add(recordlinkage.index.Full())
4  candidate_links = indexer.index(left, right)
5
6  compare = recordlinkage.Compare()
7  compare.string("drug_name", "iupac_name",
8               method="jarowinkler", label="sim_jw")
9  features = compare.compute(candidate_links, left, right)
10
11 # Estrategia de resolución (Trust-One-Source con cascada)
12 def resolver_nombre(row):
```

```
13     sider = str(row["drug_name"]).strip()
14     iupac = str(row["iupac_name"]).strip()
15     if sider and sider.lower() not in ("nan", "none", ""):
16         return sider          # Prioridad 1: nombre SIDER (INN/comercial)
17     if iupac and iupac.lower() not in ("nan", "none", ""):
18         return iupac          # Prioridad 2: nombre IUPAC
19     return "desconocido"      # Prioridad 3: marcador de ausencia
```

Listing 5.2: Record linkage y resolución de nombres desde fusion.py

Decisión metodológica: Prioridad al nombre SIDER sobre IUPAC

El nombre SIDER proviene de las etiquetas regulatorias de medicamentos y corresponde al nombre INN (*International Nonproprietary Name*) o al nombre comercial. Los nombres INN son adoptados internacionalmente por la OMS y son los que utilizan los profesionales de salud, los sistemas de prescripción electrónica y la literatura clínica. El nombre IUPAC, aunque químicamente preciso, es frecuentemente inutilizable en contexto clínico: “2-acetyloxyethyl(trimethyl)azanium” en lugar de “acetylcholine”. Dado que el reporte se dirige a farmacovigilancia (dominio clínico), la legibilidad del nombre tiene valor funcional.

5.3. P3 → Validación y canonicalización con RDKit

La validación de SMILES implementa tres niveles de verificación:

```
1 def smiles_ok(s):
2     # Nivel 1: parsing sintactico
3     # Nivel 2: sanitizacion quimica (valencias, aromaticidad)
4     # CORRECCION: el parser puede aceptar SMILES con valencia incorrecta
5     #               sin SanitizeMol(), esos errores pasan inadvertidos.
6     try:
7         mol = Chem.MolFromSmiles(str(s))
8         if mol is None or mol.GetNumAtoms() == 0:
```

```
9         return False
10         Chem.SanitizeMol(mol)    # verifica valencias y aromaticidad
11         return True
12     except Exception:
13         return False
14
15 def canonicalizar_smiles(s):
16     # CORRECCION: normaliza la representacion SMILES.
17     # Distintos generadores producen SMILES distintos para la misma
18     # molecula, generando fingerprints artificialmente distintos.
19     try:
20         mol = Chem.MolFromSmiles(str(s))
21         if mol is not None:
22             return Chem.MolToSmiles(mol) # forma canonica de RDKit
23     except Exception:
24         pass
25     return s
```

Listing 5.3: Validación y canonicalización de SMILES con RDKit (limpieza.py — versión corregida)

5.4. P4 → Deduplicación por clave compuesta

La deduplicación elimina registros con la misma combinación (drug_id, adverse_reaction):

```
1 before = len(canonical)                # 163,206
2 canonical = canonical.drop_duplicates(
3     subset=["drug_id", "adverse_reaction"]
4 )
5 after = len(canonical)                  # 152,759
6 print(f"Duplicados eliminados: {before-after:,} ({(before-after)/before
7     *100:.1f}%)")
# Output: Duplicados eliminados: 10,447 (6.4%)
```

Listing 5.4: Deduplicación por clave (drug_id, adverse_reaction) desde fusion.py

5.5. P5 → Morgan Fingerprints + Tanimoto + PCA + k-means

El pipeline de análisis molecular responde la pregunta de investigación mediante cuatro etapas:

5.5.1. Teoría de Morgan Fingerprints (ECFP4)

Los Morgan fingerprints, también conocidos como ECFP (*Extended Connectivity Fingerprints*), fueron descritos por [Morgan \(1965\)](#) y refinados en su forma moderna por [Rogers and Hahn \(2010\)](#). El algoritmo construye una representación vectorial de la molécula capturando el entorno estructural de cada átomo a distintas distancias:

Paso 1 – Inicialización: A cada átomo i se le asigna un identificador inicial $id_{i,0}$ basado en sus propiedades atómicas:

$$id_{i,0} = \text{hash}(Z_i, n_{H_i}, n_{\text{vecinos},i}, q_i, \delta_i)$$

donde Z_i es el número atómico, n_{H_i} el número de hidrógenos, $n_{\text{vecinos},i}$ el grado del átomo en el grafo molecular, q_i la carga formal, y δ_i un indicador de aromaticidad.

Paso 2 – Propagación iterativa: En cada iteración r (de 0 a $R_{\text{máx}}$):

$$id_{i,r} = \text{hash}(id_{i,r-1}, \{(b_{ij}, id_{j,r-1}) : j \in \mathcal{N}(i)\})$$

donde b_{ij} es el orden del enlace entre átomos i y j , y $\mathcal{N}(i)$ es el conjunto de vecinos del átomo i .

Paso 3 – Proyección en vector de bits: Los identificadores de todos los átomos en todas las iteraciones $r = 0, 1, \dots, R_{\text{máx}}$ se hashean a posiciones en un vector binario de N bits: $\mathbf{fp} \in \{0, 1\}^N$.

Decisión metodológica: Radio $R = 2$ (ECFP4) y 1,024 bits

Radio $R = 2$ captura fragmentos de hasta 5 átomos (el átomo central más 2 capas de vecinos), correspondiente al “diámetro 4” de la nomenclatura ECFP. Este radio es el estándar de facto en virtual screening, validado exhaustivamente por [Rogers and Hahn \(2010\)](#) como óptimo para capturar información farmacofórica sin sobre-especificarse a moléculas individuales. Con 1,024 bits se logra el balance entre densidad de información (suficiente para distinguir compuestos similares) y eficiencia computacional. El aumento a 2,048 bits añade información marginal ($< 2\%$ de mejora en benchmarks estándar) a costo computacional doble para la matriz Tanimoto.

5.5.2. Similitud Tanimoto

La similitud Tanimoto (o coeficiente de Jaccard para vectores de bits) entre dos fingerprints $\mathbf{a}$ y $\mathbf{b}$ se define como:

$$T(\mathbf{a}, \mathbf{b}) = \frac{|\mathbf{a} \cap \mathbf{b}|}{|\mathbf{a} \cup \mathbf{b}|} = \frac{c}{a + b - c}$$

donde $a = \sum_k a_k$ es el número de bits activos en $\mathbf{a}$, $b = \sum_k b_k$ en $\mathbf{b}$, y $c = \sum_k a_k b_k$ el número de bits activos en ambos. El umbral convencional de “similitud molecular significativa” es $T \geq 0.4$ ([Maggiora et al. 2014](#)).

5.5.3. Análisis de Componentes Principales

El PCA ([Pearson 1901](#)) transforma los 1,024 bits del fingerprint en componentes ortogonales ordenadas por varianza explicada. Para la visualización se usan las dos primeras componentes (PC1 y PC2).

5.5.4. Clustering k-means

k -means minimiza la inercia total:

$$\min_S \sum_{k=1}^K \sum_{\mathbf{x} \in \mathcal{S}_k} \|\mathbf{x} - \boldsymbol{\mu}_k\|^2$$

donde $\boldsymbol{\mu}_k$ es el centroide del cluster k . El silhouette score para $k = 2$ resultó en el máximo valor (0.4035), mientras que $k = 5$ produce 0.0179. La elección de $k = 5$ se justifica por criterios de dominio: corresponde aproximadamente a las grandes clases farmacológicas representadas en SIDER (antiinflamatorios, psicofármacos, antibióticos, cardiovasculares, hormonales), priorizando la interpretabilidad clínica sobre la optimización estadística pura.

Capítulo 6

Perfilado de Datos — Fase Medir

El perfilado de datos es la primera operación que se ejecuta sobre el modelo canónico, antes de cualquier transformación. Su objetivo es obtener una línea base cuantitativa del estado de calidad que permita: (1) identificar los problemas presentes, (2) establecer umbrales de mejora, y (3) comparar el estado antes y después de la limpieza para cuantificar el progreso (TDQM: Fase Medir).

6.1. Metodología y herramientas

Se emplean dos enfoques complementarios:

- **ydata-profiling**: Genera un reporte HTML interactivo con estadísticas univariadas (distribución, cuartiles, entropía), bivariadas (correlaciones de Pearson y Spearman, interacciones) y alertas de calidad automáticas. Por limitaciones de memoria y tiempo de cómputo, se ejecuta sobre una muestra de 20,000 registros extraídos aleatoriamente con semilla fija (`random_state=42`) del dataset de 152,759 filas.
- **Métricas ad hoc sobre el dataset completo**: Para garantizar precisión estadística en las métricas de calidad, todas las proporciones (completitud, unicidad, consistencia) se calculan sobre el dataset completo, no sobre la muestra.

Decisión metodológica: Muestra de 20,000 para ydata-profiling

El dataset completo (152,759 filas $\times$ 10 columnas) generaría un reporte HTML de más de 500 MB y requeriría más de 30 minutos de cómputo en hardware estándar. La muestra de 20,000 (13.1 % del total) es estadísticamente representativa para estadísticas descriptivas: el intervalo de confianza al 95 % para una proporción p con $n = 20,000$ tiene un margen de error máximo de $\pm 0.69\%$, más que suficiente para la interpretación cualitativa del perfilado.

6.2. Estructura del dataset antes de limpieza

El modelo canónico `e_drugDB_smiles.csv` (fase anterior a la limpieza) tiene la siguiente estructura:

Cuadro 6.1: Estructura y estadísticas del modelo canónico antes de limpieza

Columna	Tipo	% Com- pleto	Únicos	Descripción
drug_id	string	100.0 %	1,556	DRUG_XXXXXXXXX (CID zero-padded)
name	string	100.0 %	1,429	Nombre INN/SIDER normalizado
smiles	string	100.0 %	1,555	Estructura molecular SMILES
adverse_reaction	string	100.0 %	4,251	Término MedDRA PT
reaction_type	string	100.0 %	4,241	Código UMLS MedDRA
severity	string	0.0 %*	1	*100 % = “unknown” antes de imputación
source	string	100.0 %	1	SIDER+PubChem
pubchem_cid	int64	100.0 %	1,556	CID numérico de PubChem
stitch_flat	string	100.0 %	1,556	STITCH ID flat (sin estéreo)

*La completitud de severity se refiere a valores informativos; el campo existe pero contiene solo “unknown”

6.3. Métricas por dimensión de calidad

La Tabla 6.2 presenta los valores obtenidos calculados sobre el dataset completo:

Cuadro 6.2: Métricas de calidad antes de limpieza (calculadas sobre 152,759 filas)

Métrica	Valor	Umbral	Estado
Compleitud — <code>smiles</code>	100.0 %	$\geq 95 \%$	OK
Compleitud — <code>name</code>	100.0 %	$\geq 95 \%$	OK
Compleitud — <code>adverse_reaction</code>	100.0 %	$\geq 95 \%$	OK
Compleitud — <code>reaction_type</code>	100.0 %	$\geq 95 \%$	OK
Compleitud — <code>severity</code>	0.0 %	$\geq 80 \%$	CRÍTICO
Unicidad — pares únicos	100.0 %	$= 100 \%$	OK*
Consistencia — fuente válida	100.0 %	$= 100 \%$	OK
Consistencia — CID numérico	100.0 %	$= 100 \%$	OK
Exactitud — SMILES longitud >2	99.9 %	$= 100 \%$	REVISAR
Validez — SMILES parseable (muestra 2k)	100.0 %	$= 100 \%$	OK

*La unicidad es 100 % sobre `e_drugDB_smiles.csv` (ya deduplicado). El dataset crudo tenía 6.4 % de duplicados.

Hallazgo clave: Problema crítico: `severity = 0 %` de cobertura informativa

La única dimensión en estado crítico es la completitud del campo `severity`: el 100 % de los valores es “unknown”. Esto no se debe a datos faltantes en sentido técnico (el campo existe), sino a que la fuente base (`sider_se_pt.csv`) no incluye información de frecuencia —esta información está en un archivo separado (`meddra_freq.tsv`) que requiere una operación de join adicional para imputarla.

6.4. Análisis de distribuciones

6.4.1. Top 20 reacciones adversas más frecuentes




Figura 6.1: Top 20 reacciones adversas más frecuentes por número de fármacos asociados. La dominancia de síntomas gastrointestinales y cutáneos refleja el sesgo del dataset hacia fármacos de uso sistémico con perfil de toxicidad gastrointestinal conocido.

Las 5 reacciones más frecuentes son Nausea (1,299 fármacos), Headache (1,198), Dermatitis (1,190), Rash (1,176) y Vomiting (1,170). La dominancia de síntomas gastrointestinales y dermatológicos es consistente con la literatura: estos son los efectos adversos más comúnmente reportados en las etiquetas regulatorias de medicamentos, pues son fácilmente reconocibles y frecuentemente mencionados en los ensayos clínicos ([Lindquist 2008](#)).

6.4.2. Distribución de reacciones por fármaco




Figura 6.2: Distribución de reacciones adversas únicas por fármaco. La distribución es marcadamente asimétrica a la derecha (sesgada positivamente): la mayoría de los fármacos tiene entre 1 y 150 reacciones, pero existe una cola larga de fármacos polifarmacológicos con más de 400 reacciones.

La distribución tiene mediana = 67 reacciones y media = 98.2, con una asimetría positiva pronunciada. Esta distribución refleja el perfil farmacológico del corpus: los fármacos más recientes y específicos (anticuerpos monoclonales, inhibidores de kinasas) tienden a tener perfiles de RAM más acotados, mientras que los antipsicóticos atípicos y antiepilépticos de amplio espectro tienen perfiles extensos.

6.4.3. Completitud por columna




Figura 6.3: Porcentaje de valores no nulos por columna del modelo canónico. Todas las columnas excepto **severity** tienen completitud del 100 %, lo que confirma que la integración fue exitosa y que el único problema de completitud es estructural (campo no disponible en la fuente base).

6.4.4. Top 20 fármacos por número de reacciones




Figura 6.4: Top 20 fármacos con más reacciones adversas únicas reportadas. La lista está dominada por psicofármacos de amplio espectro (aripiprazol, pregabalina, citalopram), consistente con su mecanismo multitarget sobre el sistema nervioso central.

6.5. Métricas de calidad visualizadas




Figura 6.5: Métricas de calidad por dimensión antes de la limpieza. La mayoría de las dimensiones están al 100 %, con la excepción crítica de severity (0 %) y la advertencia en exactitud de SMILES por longitud (99.9 %, que corresponde a un único compuesto con SMILES de longitud ≤ 2).

6.6. Causas raíz de los problemas identificados

Cuadro 6.3: Análisis de causas raíz de problemas de calidad detectados en el perfilado

Dimensión	Síntoma observado	Causa raíz técnica	Causa raíz de negocio
Compleitud	<code>severity = 100 %</code> “unknown”	Campo en archivo separado (<code>meddra_freq.tsv</code>) no integrado	Las etiquetas regulatorias no siempre reportan frecuencias cuantitativas estandarizadas
Consistencia	54.1 % de pares con $d_{JW} < 0.50$	Dos fuentes con nomenclaturas independientes (INN vs IUPAC)	IUPAC es sistemático; INN es regulatorio/comercial —diseñados con objetivos distintos
Unicidad	10,447 duplicados (6.4 %)	STITCH IDs codifican estereoisómeros como registros separados	SIDER fue diseñado para nivel molecular estereoquímico; el análisis opera a nivel de CID base
Exactitud	0.06 % de SMILES con longitud ≤ 2	Iones simples (Ca^{2+} , Cl^-) con representaciones muy cortas	Medicamentos que contienen iones minerales tienen SMILES válidos pero atípicamente cortos

Capítulo 7

Limpieza de Datos — Fase Mejorar

La fase de limpieza (TDQM: Mejorar) implementa las correcciones identificadas en el perfilado. Se aplican en el siguiente orden: (1) imputación de severity, (2) validación y canonicalización de SMILES, (3) normalización de nombres, (4) normalización de términos MEDDRA, y (5) análisis de outliers por IQR.

7.1. Imputación de severity desde `meddra_freq.tsv`

Para el lector no especialista

El campo `severity` nos dice con qué frecuencia ocurre una reacción adversa: ¿la sufre 1 de cada 10 pacientes, o 1 de cada 10,000? Sin este dato, no podemos distinguir una señal de alta prioridad (`very common`) de una rarísima. El archivo `meddra_freq.tsv` tiene esta información para muchos fármacos, y la imputamos a nuestro modelo canónico mediante un `join`.

El archivo `meddra_freq.tsv` contiene etiquetas de frecuencia cualitativa derivadas de las etiquetas regulatorias de los medicamentos. La correspondencia con las convenciones cuantitativas de MEDDRA es:

Cuadro 7.1: Mapeo de etiquetas cualitativas a categorías MedDRA de frecuencia

Etiqueta en fuente	Frecuencia numérica	Categoría asignada
very common, very frequent	$\geq 1/10$ ($\geq 10\%$)	very_common
common, frequent	$\geq 1/100$ y $< 1/10$	common
uncommon, infrequent	$\geq 1/1,000$ y $< 1/100$	uncommon
rare	$\geq 1/10,000$ y $< 1/1,000$	rare
very rare	$< 1/10,000$	very_rare
postmarketing	Señal post-comercialización	postmarketing

```

1 SEVERITY_MAP = {
2     "very common": "very_common", "common": "common",
3     "frequent": "common", "uncommon": "uncommon",
4     "infrequent": "uncommon", "rare": "rare",
5     "very rare": "very_rare", "postmarketing": "postmarketing",
6 }
7
8 ORDER = {"very_common":5, "common":4, "uncommon":3,
9         "rare":2, "very_rare":1, "postmarketing":0}
10
11 freq_pt["sev_rank"] = freq_pt["severity_calc"].map(ORDER).fillna(-1)
12
13 # Conservar la severidad MAS ALTA reportada por par (stitch_flat, RAM)
14 # Justificacion: principio de precaucion en farmacovigilancia (GVP
15     Module VI)
16 best_sev = (
17     freq_pt.dropna(subset=["severity_calc"])
18     .sort_values("sev_rank", ascending=False)
19     .drop_duplicates(subset=["stitch_flat", "umls_meddra"])
20 )

```

```

21 # Join con el modelo canonico
22 df = df.merge(best_sev[["stitch_flat","reaction_type","severity_calc"]],
23               on=["stitch_flat", "reaction_type"], how="left")
24 df["severity"] = df["severity_calc"].fillna(df["severity"])

```

Listing 7.1: Imputación de severity desde meddra_freq.tsv (limpieza.py)

Decisión metodológica: Estrategia “severidad más alta” ante reportes conflictivos

Cuando un mismo par (fármaco, reacción) tiene múltiples registros con frecuencias distintas en distintos estudios (por ejemplo, “common” en un ensayo europeo y “uncommon” en un ensayo norteamericano), se asigna la categoría de mayor frecuencia. Esta decisión sigue el principio de precaución en farmacovigilancia (*primum non nocere*): ante incertidumbre, asumir el riesgo mayor protege al paciente. La guía GVP Module VI de la EMA ([European Medicines Agency 2017](#)) establece explícitamente este principio para la clasificación de señales de seguridad.

Resultado de la imputación:

Cuadro 7.2: Distribución de severity tras imputación

Categoría	Frecuencia (MedDRA)	Registros	%
unknown	No disponible	89,588	58.6 %
common	1–10 %	20,760	13.6 %
postmarketing	Post-comercialización	15,554	10.2 %
uncommon	0.1–1 %	10,659	7.0 %
very_common	≥ 10 %	9,269	6.1 %
rare	0.01–0.1 %	5,471	3.6 %
very_rare	< 0.01 %	1,458	1.0 %
Total		152,759	100 %
Mejora		0.0 % $\rightarrow$ 41.4 % cobertura informativa	




Figura 7.1: Distribución de categorías de severidad/frecuencia tras imputación. El 58.6 % permanece como “unknown” (no disponible en meddra_freq.tsv), mientras que el 41.4 % restante muestra un perfil de riesgo dominado por reacciones comunes y post-comercialización.

7.2. Validación y canonicalización de SMILES

```
1 def smiles_ok(s):
2     # Incluye SanitizeMol(): detecta valencias incorrectas que
3     # el parser acepta pero que son químicamente imposibles.
4     try:
5         mol = Chem.MolFromSmiles(str(s))
6         if mol is None or mol.GetNumAtoms() == 0:
7             return False
8         Chem.SanitizeMol(mol)
9         return True
10    except Exception:
11        return False
12
13 def canonicalizar_smiles(s):
14     # Normaliza la representación SMILES al canónico de RDKit.
15     # Garantiza que la misma molécula siempre produce el mismo
```

```
16     # fingerprint Morgan, independientemente del generador de SMILES.
17     try:
18         mol = Chem.MolFromSmiles(str(s))
19         if mol is not None:
20             return Chem.MolToSmiles(mol)
21     except Exception:
22         pass
23     return s
24
25 df["smiles_valido"] = df["smiles"].apply(smiles_ok)
26 # Resultado: 100.00% validos (0 invalidos)
27
28 df["smiles"] = df["smiles"].apply(canonicalizar_smiles)
29 # Resultado: 152,759 SMILES canonicos
```

Listing 7.2: Pipeline de validación + canonicalización de SMILES (limpieza.py — versión corregida)

Resultado: 100.00 % de los SMILES son válidos. La canonicalización afecta la representación textual de muchos compuestos sin cambiar la estructura química subyacente.

7.3. Normalización de nombres de medicamentos

```
1 def normalizar_nombre(s):
2     if pd.isna(s) or str(s).strip().lower() in ("nan", "none", ""):
3         return None
4     s = str(s).strip()
5     s = re.sub(r"\s+", " ", s) # espacios multiples → uno
6     s = re.sub(r"[^\w\s\-\\(\)\[\],\.\']+", "", s) # chars especiales raros
7     s = s.title() # Title Case
8     # Correcciones post-title para acronimos farmacologicos comunes
9     s = re.sub(r"\bAsa\b", "ASA", s) # acido acetilsalicilico
10    s = re.sub(r"\bPge2\b", "PGE2", s) # prostaglandina E2
```

```
11     s = re.sub(r"\bActh\b", "ACTH", s)    # corticotropina
12     s = re.sub(r"\bFsh\b", "FSH", s)     # hormona foliculo-estimulante
13     return s
```

Listing 7.3: Función de normalización de nombres de fármacos (limpieza.py)

Las transformaciones aplicadas son: (1) eliminación de espacios múltiples, (2) eliminación de caracteres especiales no farmacológicos, (3) conversión a Title Case, y (4) corrección de acrónimos que `.title()` normaliza incorrectamente (“ASA” → “Asa” → corregido a “ASA”).

Resultado: 777 nombres modificados de 1,556 únicos (49.9 % de los fármacos con al menos un cambio de normalización). El alto porcentaje refleja que la conversión a Title Case y la eliminación de espacios afectan a la mayoría de los nombres.

7.4. Análisis de outliers por IQR

Se analiza la distribución de reacciones adversas por fármaco para identificar outliers estadísticos y tomar una decisión informada sobre su tratamiento:

```
1  reac_por_drug = df.groupby("drug_id")["adverse_reaction"].nunique()
2
3  Q1, Q3 = reac_por_drug.quantile(0.25), reac_por_drug.quantile(0.75)
4  IQR     = Q3 - Q1
5  limite_alto = Q3 + 1.5 * IQR
6  # Q1=33, Q3=129, IQR=96, limite_alto=273
7
8  outliers_high = reac_por_drug[reac_por_drug > limite_alto]
9  # Resultado: 94 farmacos con > 273 reacciones adversas unicas
```

Listing 7.4: Análisis de outliers por IQR sobre reacciones por fármaco (limpieza.py)

Resultados cuantitativos:

$$Q_1 = 33 \quad Q_3 = 129 \quad \text{IQR} = 96 \quad \text{Límite alto} = 129 + 1.5 \times 96 = 273$$

94 fármacos superan el límite superior. Los 5 con más reacciones reportadas son:

Cuadro 7.3: Top 5 fármacos outlier por número de reacciones adversas únicas

Fármaco	RAM únicas	Clase	Justificación clínica
Pregabalina	742	Antiepiléptico/Analgésico	Actúa sobre subunidades $\alpha_2\delta$ de canales de Ca^{2+} ; mecanismo de acción con consecuencias sistémicas
Aripiprazol	741	Antipsicótico atípico	Agonismo parcial D2/D3, agonismo 5-HT1A, antagonismo 5-HT2A; multitarget por diseño (Stahl 2016)
Citalopram	722	ISRS	Inhibidor selectivo de recaptación de serotonina; mayor tiempo en el mercado = mayor base de datos de RAM
Pramipexol	611	Agonista dopaminérgico	La dopamina regula múltiples sistemas (motor, cognitivo, límbico); RAM sistémicamente amplias
Ropinirol	607	Agonista dopaminérgico	Misma clase y mecanismo que pramipexol

Decisión metodológica: Conservar todos los outliers: evidencia clínica supera criterio estadístico

En análisis estadístico de poblaciones generales, los outliers suelen eliminarse por ser “ruido”. En farmacovigilancia, este principio no aplica: el número de reacciones adversas reportadas para un fármaco es una señal real de su perfil farmacológico, no un error de medición. Eliminar a pregabalina del análisis porque tiene “demasiadas” RAM registradas sería científicamente incorrecto: su extenso perfil de RAM es información válida y documentada en la literatura clínica (Dworkin et al. 2007). El análisis IQR se reporta para transparencia metodológica, no para guiar la eliminación de datos.




Figura 7.2: Boxplot e histograma de reacciones adversas por fármaco. La línea roja discontinua marca el límite superior por IQR (273 reacciones). Los 94 fármacos por encima del límite son polifarmacológicos con perfiles de RAM ampliamente documentados en la literatura clínica.

7.5. Comparación antes vs. después de la limpieza




Figura 7.3: Comparación de completitud en las tres dimensiones intervenidas por la limpieza. La mejora más significativa es la de severity: de 0 % a 41.4 %, un incremento de 41.4 puntos porcentuales. Las otras dos dimensiones ya estaban al 100 % (SMILES válidos) o cerca (nombres normalizados).




Figura 7.4: Comparación completa de todas las métricas de calidad antes y después de la limpieza. La única dimensión que muestra mejora es la completitud de severity. Las demás ya estaban al nivel máximo, lo que confirma que la integración por CID fue exitosa en construir un modelo canónico internamente consistente.

Cuadro 7.4: Resumen comparativo cuantitativo: antes vs. después de limpieza

Métrica	Antes	Después	Δ
Filas totales	152,759	152,759	0
Severity conocida (%)	0.0 %	41.4 %	+41.4pp
SMILES válidos (%)	100.0 %	100.0 %	0
Nombres normalizados (%)	~50 %*	100.0 %	+50.0pp
Duplicados exactos	0	0	0

*Estimado pre-normalización; la normalización es idempotente sobre nombres ya limpios.

Capítulo 8

Datos Maestros: Modelo Canónico, Record Linkage y Fusión

8.1. Fundamentos de Master Data Management

El *Master Data Management* (MDM) es la disciplina que garantiza que los datos de referencia de una organización —aquellos que son compartidos y utilizados por múltiples sistemas— sean consistentes, precisos y gobernados de forma centralizada ([DAMA International 2017](#)). El modelo canónico (*golden record*) es el artefacto central del MDM: la representación única, autoritativa y reconciliada de cada entidad.

En este proyecto, la entidad central es el par (**fármaco, reacción adversa**). El modelo canónico `e_drugDB_clean.csv` es el golden record que consolida información de dos fuentes heterogéneas en una representación unificada.

8.2. Diseño del modelo canónico

Cuadro 8.1: Diccionario de variables del modelo canónico `e_drugDB_clean.csv`

Variable	Tipo	Fuente	Descripción y justificación
<code>drug_id</code>	string	Derivado	“DRUG_” + CID zero-padded a 8 dígitos. Zero-padding garantiza ordenamiento lexicográfico consistente con numérico; el prefijo “DRUG_” evita colisiones con otros sistemas
<code>name</code>	string	SIDER>PubChem	Nombre INN/comercial preferido. SIDER tiene prioridad por legibilidad clínica
<code>smiles</code>	string	PubChem	SMILES canónico RDKit. Representación única, reproducible
<code>adverse_reaction</code>	string	SIDER	Término PT de MEDDRA. Nivel de especificidad clínica óptimo
<code>reaction_type</code>	string	SIDER	Código UMLS del término PT. Permite interoperabilidad con sistemas clínicos (SNOMED, ICD)
<code>severity</code>	string	meddra_freq	Categoría de frecuencia MedDRA. Escala ordinal: <code>very_common</code> > <code>common</code> > <code>uncommon</code> > <code>rare</code> > <code>very_rare</code>
<code>source</code>	string	Derivado	Trazabilidad de proveniencia. Auditoría de calidad
<code>pubchem_cid</code>	int64	PubChem	Clave foránea a PubChem. Permite enriquecimiento futuro con nuevos datos de PubChem sin modificar el modelo

8.3. Record Linkage: metodología detallada

El proceso de record linkage sigue cuatro etapas:

Etapas 1 — Preparación: Se construye una tabla de un registro por CID, con `drug_name` (de SIDER) e `iupac_name` (de PUBCHEM), para comparar los nombres de ambas fuentes para el mismo fármaco.

Etapas 2 — Indexación: En lugar de comparar todos los pares posibles ($n^2/2 = 1,210,090$ pares para 1,556 fármacos), se usa el propio CID para hacer el bloqueo: cada fármaco se compara solo consigo mismo (a través de sus dos representaciones de nombre). Esto reduce la complejidad de $O(n^2)$ a $O(n)$.

Etapas 3 — Comparación: Se calculan dos métricas de similitud de string para cada par:

- d_{JW} : Jaro-Winkler (métrica principal, diseñada para nombres cortos)
- d_{lev} : Levenshtein normalizado (métrica de contraste para validación)

Etapas 4 — Clasificación: Los pares se clasifican en tres categorías:

Cuadro 8.2: Resultados del record linkage por categoría de similitud Jaro-Winkler

Categoría	Umbral d_{JW}	Fármacos	%
Alta similitud	≥ 0.85	37	2.4 %
Similitud media	$[0.50, 0.85)$	678	43.6 %
Baja similitud	< 0.50	841	54.1 %
Total		1,556	100 %
Promedio $\bar{d}_{JW}$		0.495	

Hallazgo clave: La heterogeneidad semántica es la norma: solo 2.4 % de fármacos con nombres similares entre fuentes

Con una similitud promedio $\bar{d}_{JW} = 0.495$ —justo en el límite de “similitud media”— y solo 37 de 1,556 pares con alta similitud (básicamente iones inorgánicos como “acetate”, “calcium”, “chloride”), el dataset confirma que los nombres INN y los nombres IUPAC son fundamentalmente incompatibles para la integración directa. La dependencia del PubChem CID como ancla del join es, por tanto, no un capricho de diseño sino una necesidad técnica demostrada por los datos.

8.4. Arquitectura de integración

La Figura 8.1 describe el flujo completo de datos desde las fuentes crudas hasta el modelo canónico limpio.

```

SIDER 4.1                                PubChem

+-----+                               +-----+
| sider_se_pt.csv      |               | pubchem_smiles.csv  |
| 163,206 filas       |               | 1,556 filas        |
| stitch_flat -----+--JOIN(CID)---+> pubchem_cid      |
| pubchem_cid         |               | smiles (SMILES)   |
| umls_meddra         |               | iupac_name        |
| side_effect_name    |               +-----+-----+
+-----+-----+                       |
|               sider_drug_names.csv    |
|               +-----+               |
+---JOIN---| stitch_flat |               |
|               drug_name |               |
|               +-----+               |
|               +-----+-----+       |
|               +-----+-----+       |
|               |                       |
|               V                       |
|               +-----+               |
| e_drugDB.csv      |               |
| 163,206 filas     |               |
| Modelo canonico crudo |         |
|               +-----+-----+       |
|               |                       |
|               fusion.py               |
|               (deduplicacion)         |
|               |                       |
|               +-----+-----+       |
|               V                       |
| e_drugDB_smiles.csv |               |
| 152,759 filas      |               |
| (10,447 dedup 6.4%) |               |

```

Capítulo 9

Preprocesamiento y Análisis Molecular

Este capítulo presenta el núcleo científico del proyecto: el análisis de las propiedades moleculares de los fármacos y su relación con el perfil de reacciones adversas. Se organiza en cuatro secciones correspondientes a las secciones A, B, C y D del script `análisis.py`.

9.1. Análisis sobre SIDER (Fuente Individual — Sección A)

9.1.1. Top 15 reacciones adversas (A1)




Figura 9.1: A1 — Top 15 reacciones adversas más reportadas en SIDER 4.1 por número de fármacos asociados. La lista es consistente con la conocida jerarquía de RAM más comunes en medicamentos de uso sistémico: síntomas gastrointestinales (nausea, vómito, diarrea), del sistema nervioso (cefalea, mareo) y dermatológicos (rash, dermatitis). Esta distribución refleja la cobertura del corpus, no la frecuencia real de RAM en la población.

9.1.2. Co-ocurrencia de reacciones (A5)




Figura 9.2: A5 — Matriz de co-ocurrencia de las 10 reacciones adversas más frecuentes. Cada celda indica el número de fármacos que presentan simultáneamente ambas reacciones. El par (Nausea, Vomiting) tiene la mayor co-ocurrencia (>900 fármacos), lo que es farmacológicamente esperable dado que ambas comparten mecanismos emetogénicos. La alta co-ocurrencia de síntomas gastrointestinales con reacciones dermatológicas sugiere que los fármacos con acción sistémica tienden a tener perfiles de RAM amplios.

9.2. Análisis sobre PubChem (Fuente Individual — Sección B)

9.2.1. Distribución de peso molecular (B1)




Figura 9.3: B1 — Distribución de peso molecular de los 1,556 fármacos. La distribución es bimodal y sesgada positivamente: el modo principal está alrededor de 300–500 Da (fármacos de síntesis clásicos), con una cola hacia moléculas más grandes (péptidos, macromoléculas). La línea roja discontinua marca el límite de Lipinski ($MW \leq 500$ Da). La media de 500.2 Da indica que el corpus incluye una proporción significativa de fármacos que transgreden la regla de Lipinski en peso molecular.

El peso molecular medio de 500.2 Da (D.E. = 672.1 Da) con alta desviación estándar refleja la heterogeneidad del corpus: desde moléculas pequeñas como el ácido 4-aminobutanóico (GABA, $MW = 103$ Da) hasta macromoléculas peptídicas de más de 5,000 Da. El 69.9% de los fármacos cumplen con las cuatro reglas de Lipinski simultáneamente ($MW \leq 500$, $\log P \leq 5$, $HBD \leq 5$, $HBA \leq 10$), porcentaje consistente con un corpus de fármacos orales aprobados donde la biodisponibilidad oral es un requisito regulatorio implícito.

9.2.2. Espacio farmacológico: MW vs logP (B2)




Figura 9.4: B2 — Espacio farmacológico de Lipinski: peso molecular vs. logP coloreado por número de anillos. Los fármacos que cumplen ambas reglas (cuadrante inferior izquierdo) son la mayoría (69.9%). Los fármacos fuera del espacio de Lipinski tienden a ser péptidos (alto MW, bajo logP) o compuestos lipofílicos (alto logP, bajo MW). El gradiente de color revela que los fármacos con más anillos aromáticos tienden a ser más lipofílicos (mayor logP), consistente con la contribución electrónica de los anillos a la lipofiliidad.

9.3. Análisis cross-source SIDER + PubChem (Sección C)

9.3.1. Propiedades moleculares según categoría de severidad (C3)




Figura 9.5: C3 — Distribución del número de reacciones adversas por fármaco según la categoría de severidad de la reacción. Los fármacos cuyas reacciones se clasifican como “very_common” tienden a tener más reacciones totales reportadas (mayor mediana), lo que sugiere que los fármacos con muchas RAM también tienden a reportar más reacciones frecuentes —consistente con el perfil de los antipsicóticos atípicos y antiepilépticos del top de outliers.

9.3.2. TPSA en fármacos con reacciones neurológicas (C9)




Figura 9.6: C9 — Distribución del área polar superficial total (TPSA) en fármacos con reacciones neurológicas (azul) vs. otros fármacos (naranja). La línea verde discontinua marca $TPSA = 90 \text{ \AA}^2$, umbral empírico de penetración de la barrera hematoencefálica (BHE). Los fármacos con RAM neurológicas muestran un modo más pronunciado por debajo de $90 \text{ \AA}^2$, consistente con la hipótesis de que estos fármacos penetran la BHE —condición necesaria para causar reacciones del SNC.

La Figura 9.6 es farmacológicamente relevante: el TPSA es un descriptor molecular que predice la permeabilidad de membranas. Compuestos con $TPSA < 90 \text{ \AA}^2$ tienden a cruzar la barrera hematoencefálica. La distribución diferencial entre fármacos con RAM neurológicas y los demás es la primera evidencia cuantitativa en este dataset de que las propiedades moleculares discriminan, al menos parcialmente, el tipo de órgano diana de las reacciones adversas.

9.4. Análisis molecular con RDKit: fingerprints y Tanimoto (Sección D)

9.4.1. Cálculo de Morgan fingerprints

```
1 drug_fps = []
2 for _, r in drug_smiles.iterrows():
3     try:
4         mol = Chem.MolFromSmiles(r["smiles"])
5         if mol:
6             fp = AllChem.GetMorganFingerprintAsBitVect(
7                 mol,
8                 radius=2,          # ECFP4: captura entornos hasta 2
                                   enlaces
9                 nBits=1024,        # 1024 bits: balance info-eficiencia
10                useFeatures=False, # ECFP (no FCFP): sin features
                                   farmacofóricos
11            )
12            drug_fps.append({"drug_id":r["drug_id"],
13                            "name":r["name"], "fp":fp})
14        except Exception:
15            pass
16 # Resultado: 1,556 fingerprints generados (100% de los farmacos)
```

Listing 9.1: Cálculo de Morgan fingerprints ECFP4 para todos los fármacos (análisis.py)

9.4.2. Similitud Tanimoto entre fármacos hepatotóxicos (D1)




Figura 9.7: D1 — Mapa de calor de similitud Tanimoto entre los primeros 20 fármacos con reacciones hepáticas reportadas (hepatic failure, hepatotoxicity y relacionadas). Los bloques de color verde intenso en la diagonal de bloques indican subgrupos de fármacos con alta similitud molecular ($T > 0.4$). Esto es evidencia directa de que dentro del grupo de fármacos hepatotóxicos existen clústeres estructuralmente homogéneos, consistente con H_1 .

9.4.3. Distribución de Tanimoto por grupo de reacción (D2)




Figura 9.8: D2 — Distribución de similitud Tanimoto entre pares de fármacos del mismo grupo de reacción (top 5 reacciones adversas). La línea roja discontinua marca el umbral convencional de similitud significativa ($T = 0.4$). La mayoría de las distribuciones tienen su modo por debajo de 0.4, lo que indica que dentro de cada grupo de RAM la diversidad molecular es alta. Sin embargo, la presencia de valores $T > 0.4$ en todos los grupos confirma la existencia de subgrupos estructuralmente similares dentro de cada categoría de RAM.

Hallazgo clave: Señal molecular presente pero heterogénea: la hipótesis es verdadera para subgrupos

La similitud Tanimoto intragrupo no es uniformemente alta (lo que refutaría la diversidad del corpus), ni uniformemente baja (lo que rechazaría H_1). La distribución multimodal en D2 es la firma esperada cuando el grupo de RAM incluye tanto fármacos estructuralmente relacionados (misma clase química $\rightarrow$ alta T) como fármacos de distintas clases que convergen en el mismo efecto adverso vía mecanismos distintos (baja T). Este patrón es consistente con el estado del arte en farmacovigilancia computacional (Maciejewski et al. 2021).

9.4.4. PCA de fingerprints moleculares (D3)




Figura 9.9: D3 — Proyección PCA de los 1,556 vectores de fingerprint Morgan (1,024 dimensiones) en dos componentes principales. PC1 explica el 6.08 % de la varianza; PC2, el 3.76 %; conjuntamente el 9.84 %. El color indica el número de reacciones adversas del fármaco. La distribución no es aleatoria: existen regiones del espacio PCA con mayor densidad de fármacos con muchas RAM, sugiriendo que la estructura molecular y el número de RAM están parcialmente correlacionados.

Para el lector no especialista

Imagina que tienes 1,556 fármacos, cada uno descrito por 1,024 características (los bits del fingerprint). Es imposible visualizar 1,024 dimensiones. El PCA las comprime a 2, como proyectar una esfera en un plano. Perdemos información (el 90.16 % de la varianza queda fuera), pero la proyección conserva las similitudes más importantes: fármacos cercanos en el plano tienden a ser molecularmente similares.

La baja varianza explicada por PC1+PC2 (9.84 %) es *esperada* para vectores binarios

de alta dimensión y no invalida el análisis. [Wawer et al. \(2014\)](#) demuestran que incluso con porcentajes bajos de varianza explicada en PCA de fingerprints, la proyección 2D conserva suficiente estructura topológica para análisis exploratorio. La comparación relevante no es el porcentaje de varianza, sino la estructura visual de la proyección: ¿hay agrupamientos? ¿existe gradiente de color? La respuesta es afirmativa en ambos casos.

9.4.5. Clustering k-means sobre fingerprints (D4)




Figura 9.10: D4 — Clustering k-means ($k = 5$) sobre los 1,556 fingerprints moleculares visualizado en el espacio PCA. Los cinco clusters representan arquetipos moleculares farmacológicamente interpretables. La separación no es perfecta en el espacio 2D (reflejo de la baja varianza explicada), pero los centroides de los clusters son estadísticamente distintos en el espacio original de 1,024 dimensiones.

Evaluación estadística de k :

El análisis de silhouette scores para $k \in \{2, 3, 4, 5, 6, 7\}$ (calculado sobre las primeras

50 componentes PCA para eficiencia computacional) produce:

Cuadro 9.1: Silhouette scores para distintos valores de k en k-means

k	Silhouette score	Inercia
2	0.4035	25,640
3	0.2231	24,064
4	0.0957	22,918
5	0.0179	22,145
6	0.0245	21,566
7	0.0497	20,979

Limitación / Consideración: El silhouette score favorece $k=2$; la elección de $k=5$ requiere justificación explícita

Estadísticamente, $k = 2$ produce el mejor silhouette (0.4035), indicando dos grandes grupos naturales en el espacio molecular. Sin embargo, $k = 2$ produce clusters demasiado generales para ser farmacológicamente informativos (probablemente: moléculas pequeñas vs. macromoléculas). La elección de $k = 5$ se justifica por criterios de dominio: aproximadamente cinco grandes clases farmacológicas están representadas en el corpus (antiinflamatorios/analgésicos, psicofármacos, antiinfecciosos, cardiovasculares, hormonales), y un cluster por clase ofrece mayor interpretabilidad clínica que dos grupos genéricos. Esta es una decisión de compromiso entre optimización estadística e interpretabilidad de dominio, documentada explícitamente para transparencia metodológica.

9.5. Respuesta a la pregunta de investigación

Hallazgo clave: Conclusión: H_1 se confirma parcialmente con evidencia multinivel

La evidencia acumulada de las cuatro visualizaciones del análisis molecular (D1–D4) y el análisis cross-source (C9) es consistente con la hipótesis de investigación:

1. **D1:** Los fármacos hepatotóxicos forman subclústeres de alta similitud Tanimoto ($T > 0.4$) dentro del grupo de RAM hepáticas.
2. **D2:** La distribución de similitud intragrupo no es aleatoria; existen fármacos con RAM similares que son molecularmente similares.
3. **D3:** El espacio PCA de fingerprints tiene estructura (gradiente de color por n_{RAM}), no es ruido aleatorio.
4. **D4:** El clustering identifica 5 arquetipos moleculares con distribuciones de RAM distintas.
5. **C9:** El TPSA distingue fármacos con RAM neurológicas de los demás, siendo una propiedad molecular directamente relacionada con la capacidad de penetrar el SNC.

La señal es parcial: no todos los fármacos con la misma RAM son molecularmente similares, pero dentro de cada clase de RAM existen subgrupos estructuralmente homogéneos. Este es el patrón esperado cuando una misma RAM puede ser causada por mecanismos moleculares distintos (polietilogía de las RAM).

Capítulo 10

Conclusiones

10.1. Conclusiones de calidad de datos

Este proyecto demostró que la integración de fuentes heterogéneas de farmacovigilancia es un problema de calidad de datos antes que un problema analítico. Los principales hallazgos metodológicos son:

1. **La heterogeneidad semántica es cuantificable y su impacto es medible.** La similitud Jaro-Winkler promedio de 0.495 entre nombres SIDER e IUPAC demuestra que la integración por nombre habría fallado en el 54.1 % de los casos. El CID como identificador canónico resolvió este problema de forma determinística.
2. **Los duplicados tienen causas raíz técnicas específicas.** Los 10,447 duplicados (6.4 %) no fueron un “error” de los datos sino una consecuencia predecible de la codificación STITCH, que opera en un nivel de abstracción (estereoisómeros) diferente al del análisis (CID base). Entender la causa raíz fue esencial para elegir la solución correcta (deduplicación por CID, no por STITCH ID).
3. **La imputación de severity siguiendo el principio de precaución farmacológica elevó la cobertura 41.4 puntos porcentuales.** La decisión de asignar la

severidad más alta ante reportes conflictivos está respaldada por las guías GVP de la EMA y es reproducible mediante el código documentado.

4. **La validación con sanitización química (SanitizeMol) es superior a la validación sintáctica.** La corrección implementada en `limpieza.py` detecta valencias incorrectas que el parser de RDKit acepta sin error, garantizando la corrección química de los SMILES más allá de su corrección sintáctica.
5. **El framework TDQM estructura el proceso de forma reproducible.** La separación explícita entre Definir, Medir, Analizar y Mejorar garantiza que cada decisión tiene una motivación rastreable y que la mejora es cuantificable comparando métricas antes y después.

10.2. Conclusiones científicas

1. **La hipótesis H_1 se confirma parcialmente:** los fármacos con la misma RAM tienden a compartir subestructuras moleculares más de lo esperado por azar, pero la señal es heterogénea entre clases de RAM. Las RAM de causa molecular específica (hepatotoxicidad por fármacos de una clase química) muestran señal más fuerte que las RAM de causa inespecífica (nausea, que puede ser causada por prácticamente cualquier fármaco).
2. **El TPSA predice parcialmente la organotoxicidad:** la distribución diferencial de TPSA en fármacos con RAM neurológicas (Figura 9.6) valida que las propiedades moleculares de permeabilidad de membrana discriminan el tipo de órgano diana de las reacciones adversas.
3. **La combinación de PCA y k-means sobre fingerprints es un enfoque exploratorio válido pero no predictivo:** los 5 clusters identificados tienen interpretación farmacológica, pero el silhouette score de $k = 5$ (0.0179) indica que los límites entre

clusters son difusos —lo cual es biológicamente razonable, ya que las clases farmacológicas no tienen fronteras estructurales nítidas.

10.3. Limitaciones del estudio

Limitación / Consideración: Limitaciones que deben considerarse al interpretar los resultados

- **Obsolescencia de SIDER:** la última actualización es 2015. Los fármacos aprobados desde entonces (inmunooncológicos, terapias CAR-T, fármacos de ARNm) no están representados.
- **Sesgo de documentación:** SIDER extrae RAM de etiquetas regulatorias (FDA label). Las RAM mejor documentadas no son necesariamente las más frecuentes en la práctica clínica, sino las que pasaron los umbrales de significancia estadística en ensayos clínicos.
- **Nivel PT vs. LLT:** el uso exclusivo de términos PT puede perder granularidad. Por ejemplo, “Nausea” y “Vomiting” son PTs distintos, pero mecanísticamente relacionados.
- **Análisis no confirmatorio:** todos los análisis de la Sección D son exploratorios. No se realizan pruebas de hipótesis formales ni correcciones por comparaciones múltiples. Las conclusiones son sugestivas, no confirmatorias.
- **Generalización limitada:** las conclusiones se aplican al corpus de 1,556 fármacos de SIDER 4.1. La generalización a nuevos compuestos requiere validación prospectiva.

10.4. Trabajo futuro

1. **Integración de datos post-2015:** Incorporar datos de FAERS (FDA Adverse Event Reporting System) y EudraVigilance (EMA) para cubrir el período 2015-2026.
2. **Análisis por clase farmacológica (ATC codes):** Estratificar el análisis por clase ATC (Anatomical Therapeutic Chemical) para separar la señal estructural de la clase química del ruido inespecífico.
3. **Modelos de deep learning:** Aplicar Graph Neural Networks (GNN) sobre representaciones moleculares en grafo —más informativas que los fingerprints de bits— para predicción de RAM. El trabajo seminal de [Stokes et al. \(2020\)](#) en Cell demuestra la viabilidad de GNN para predicción de actividad biológica en el mismo tipo de corpus.
4. **Test de hipótesis formal:** Implementar el test de Mann-Whitney U para comparar distribuciones Tanimoto intragrupo vs. intergrupo, con corrección de Bonferroni por el número de RAM analizadas.
5. **Pipeline de actualización automática:** Construir un pipeline de ingesta continua que actualice el modelo canónico con nuevas etiquetas regulatorias y nuevos compuestos de PubChem usando el CID como clave de actualización incremental.

10.5. Reflexión sobre el framework TDQM

El framework TDQM demostró ser apropiado para este proyecto por su énfasis en la iteración y la cuantificación. La fase de Medir antes de cualquier modificación fue crítica: sin el perfilado inicial, habría sido imposible cuantificar la mejora lograda en la fase de Mejorar. El ciclo iterativo también reveló que la fase de Analizar (identificar causas raíz) es conceptualmente la más difícil: distinguir el síntoma (duplicados) de la causa (codificación STITCH) requirió conocimiento del dominio farmacológico que no está en los datos mismos.

Este hallazgo apoya la conclusión general del proyecto: los frameworks de calidad de datos son herramientas necesarias pero no suficientes. La calidad de datos en dominios especializados (farmacovigilancia, genómica, imagen médica) requiere la integración de conocimiento de dominio experto en cada fase del proceso.

Bibliografía

- Almenoff, J. S., Pattishall, E. N., Gibbs, T. G., DuMouchel, W., Evans, S. J. W., and Yuen, N. (2007). Novel statistical tools for monitoring the safety of marketed drugs. *Clinical Pharmacology & Therapeutics*, 82(2):157–166.
- Brown, N., Fiscato, M., Segler, M. H. S., and Vaucher, A. C. (2019). GuacaMol: Benchmarking models for de novo molecular design. *Journal of Chemical Information and Modeling*, 59(3):1096–1108.
- DAMA International (2017). *DAMA-DMBOK: Data management body of knowledge*. Technics Publications, Westfield, NJ, 2 edition.
- Dworkin, R. H., O’Connor, A. B., Backonja, M., Farrar, J. T., Finnerup, N. B., Jensen, T. S., Kalso, E. A., Loeser, J. D., Miaskowski, C., Nurmikko, T. J., Portenoy, R. K., Rice, A. S. C., Stacey, B. R., Treede, R.-D., Turk, D. C., and Wallace, M. S. (2007). Pharmacologic management of neuropathic pain: Evidence-based recommendations. *Pain*, 132(3):237–251.
- European Medicines Agency (2017). Guideline on good pharmacovigilance practices (GVP) module VI—management and reporting of adverse reactions to medicinal products. Technical Report EMA/873138/2011 Rev 2, European Medicines Agency.
- Fellegi, I. P. and Sunter, A. B. (1969). A theory for record linkage. *Journal of the American Statistical Association*, 64(328):1183–1210.

- Gartner, Inc. (2021). How to improve your data quality. *Gartner Research*.
- Jaro, M. A. (1989). Advances in record-linkage methodology as applied to matching the 1985 Census of Tampa, Florida. *Journal of the American Statistical Association*, 84(406):414–420.
- Kim, S., Chen, J., Cheng, T., Gindulyte, A., He, J., He, S., Li, Q., Shoemaker, B. A., Thiessen, P. A., Yu, B., Zaslavsky, L., Zhang, J., and Bolton, E. E. (2023). PubChem 2023 update. *Nucleic Acids Research*, 51(D1):D1373–D1380.
- Kuhn, M., Letunic, I., Jensen, L. J., and Bork, P. (2016). The SIDER database of drugs and side effects. *Nucleic Acids Research*, 44(D1):D1075–D1079.
- Lenzerini, M. (2002). Data integration: A theoretical perspective. In *Proceedings of the Twenty-First ACM SIGMOD-SIGACT-SIGART Symposium on Principles of Database Systems*, pages 233–246.
- Lindquist, M. (2008). VigiBase, the WHO global ICSR database system: Basic facts. *Drug Information Journal*, 42(5):409–419.
- Lloyd, K., Ali, S., Wesselius, A., Hillege, H., and Zeegers, M. P. (2019). Data quality assessment framework to assess electronic medical record data for use in research. *International Journal of Medical Informatics*, 130:103972.
- Maciejewski, M., Lounkine, E., Whitebread, S., Farmer, P., Mai, M., Barberis, C., Jenkins, J. L., and Urban, L. (2021). Similarities in drug-target interaction patterns between drug pairs with similar side effect profiles. *PLOS Computational Biology*, 17(5):e1008831.
- Maggiora, G., Vogt, M., Stumpfe, D., and Bajorath, J. (2014). Molecular similarity in medicinal chemistry. *Journal of Medicinal Chemistry*, 57(8):3186–3204.
- Morgan, H. L. (1965). The generation of a unique machine description for chemical

- structures—A technique developed at Chemical Abstracts Service. *Journal of Chemical Documentation*, 5(2):107–113.
- Pearson, K. (1901). On lines and planes of closest fit to systems of points in space. *The London, Edinburgh, and Dublin Philosophical Magazine and Journal of Science*, 2(11):559–572.
- Rogers, D. and Hahn, M. (2010). Extended-connectivity fingerprints. *Journal of Chemical Information and Modeling*, 50(5):742–754.
- Stahl, S. M. (2016). *Stahl’s essential psychopharmacology: Neuroscientific basis and practical applications*. Cambridge University Press, Cambridge, United Kingdom, 4 edition.
- Stokes, J. M., Yang, K., Swanson, K., Jin, W., Cubillos-Ruiz, A., Donghia, N. M., MacNair, C. R., French, S., Carfrae, L. A., Bloom-Ackermann, Z., Tran, V. M., Chiappino-Pepe, A., Badran, A. H., Andrews, I. W., Chory, E. J., Church, G. M., Brown, E. D., Jaakkola, T. S., Barzilay, R., and Collins, J. J. (2020). A deep learning approach to antibiotic discovery. *Cell*, 180(4):688–702.
- Wang, R. Y. and Strong, D. M. (1996). Beyond accuracy: What data quality means to data consumers. *Journal of Management Information Systems*, 12(4):5–33.
- Wawer, M. J., Li, K., Gustafsdottir, S. M., Ljosa, V., Bodycombe, N. E., Marton, M. A., Sokolnicki, K. L., Bray, M.-A., Kemp, M. M., Winchester, E., Taylor, B., Grant, G. B., Hon, C. S.-Y., Duvall, J. R., Wilson, J. A., Bittker, J. A., Duplax, C., Bhatt, A., et al. (2014). Toward performance-diverse small-molecule libraries for cell-based phenotypic screening using multiplexed high-dimensional profiling. *Proceedings of the National Academy of Sciences*, 111(33):12131–12136.
- Weininger, D. (1988). SMILES, a chemical language and information system. 1. Introduction to methodology and encoding rules. *Journal of Chemical Information and Computer Sciences*, 28(1):31–36.

Winkler, W. E. (1990). String comparator metrics and enhanced decision rules in the Fellegi-Sunter model of record linkage. *Proceedings of the Section on Survey Research Methods, American Statistical Association*, pages 354–359.

World Health Organization (2002). The importance of pharmacovigilance: Safety monitoring of medicinal products. Technical report, World Health Organization, Geneva, Switzerland.

Apéndice A

Diccionario Completo de Variables

Cuadro A.1: Diccionario de variables del modelo canónico e_drugDB_clean.csv

Variable	Tipo	% Completo	Únicos	Descripción detallada
drug_id	string	100 %	1,556	Identificador primario del fármaco. Formato: “DRUG_” + CID de PubChem con zero-padding a 8 dígitos. Ejemplo: DRUG_00002244. No nulo, no duplicado por fármaco

(Continuación)

Variable	Tipo	% Com- pleto	Únicos	Descripción detallada
name	string	100 %	1,429	Nombre del fármaco normalizado a Title Case. Fuente: SIDER drug_name (prioridad 1), PubChem iupac_name (prioridad 2), “Desconocido” (prioridad 3). Rango: 1–777 caracteres
smiles	string	100 %	1,555	Estructura molecular en formato SMILES canónico RDKit. Válido al 100 % por Chem.MolFromSmiles() + SanitizeMol(). Fuente: PubChem CID property endpoint
adverse_reaction	string	100 %	4,251	Término MedDRA Preferred Term (PT) normalizado a Title Case. Fuente: SIDER campo side_effect_name

(Continuación)

Variable	Tipo	% Com- pleto	Únicos	Descripción detallada
reaction_typestring		100 %	4,241	Código UMLS correspondiente al término MedDRA PT. Fuente: SIDER campo umls_meddra. Permite interoperabilidad con sistemas de información clínica
severity	string	41.4 %	7	Categoría de frecuencia/severidad MedDRA. Valores: very_common, common, uncommon, rare, very_rare, postmarketing, unknown. Fuente: meddra_freq.tsv con imputación

(Continuación)

Variable	Tipo	% Com- pleto	Únicos	Descripción detallada
source	string	100 %	1	Indicador de proveniencia. Valor: “SIDER+PubChem” (integración de ambas fuentes). Diseñado para extensión futura con otras fuentes
pubchem_cid	int64	100 %	1,556	CID numérico de PubChem. Clave foránea trazable a PubChem. Rango: 119–157,880,732
stitch_flat	string	100 %	1,556	STITCH ID flat (sin información estereoquímica). Clave foránea a SIDER. Formato: CID + offset
n_reac	int64	100 %	284	Número de reacciones adversas únicas del fármaco en el dataset. Campo calculado. Rango: 1–742. Media: 98.2. Mediana: 67

Apéndice B

Ambiente Computacional y Reproducibilidad

Para garantizar la reproducibilidad completa del análisis, se documenta el ambiente computacional utilizado:

Cuadro B.1: Versiones de bibliotecas del ambiente computacional

Biblioteca	Versión	Propósito
Python	3.x	Lenguaje base
pandas	≥ 2.0	Manipulación de datos tabulares
numpy	2.3.4	Álgebra lineal numérica*
rdkit	2026.3.1	Quimioinformática y validación molecular
recordlinkage	0.16	Record linkage y comparación de strings
thefuzz	0.22.1	Fuzzy matching de cadenas
ydata-profiling	≥ 4.0	Perfilado automatizado de datos
scikit-learn	≥ 1.3	PCA y k-means clustering
matplotlib	≥ 3.7	Visualización científica
seaborn	≥ 0.12	Visualización estadística
python-pptx	1.0.2	Generación de presentaciones

*numpy==2.3.4 forzado: numpy 2.4 es incompatible con numba/ydata-profiling

Instrucciones de reproducción:

```

1  # 1. Instalar dependencias
2  pip install pandas numpy==2.3.4 rdkit recordlinkage thefuzz \
3      ydata-profiling scikit-learn matplotlib seaborn \
4      python-Levenshtein
5
6  # 2. Ejecutar en orden (cada script depende del anterior)
7  cd calidadproyecto/
8
9  python datos/fusion.py          # Genera e_drugDB_smiles.csv
10 python perfilado.py             # Perfilado ANTES (secciones 1-5)
11 python limpieza.py             # Genera e_drugDB_clean.csv
12 python perfilado.py            # Perfilado DESPUES (secciones 6-10)
13 python analisis.py             # Genera 24 graficas

```

```
14
15 # 3. Compilar el reporte
16 pdflatex reporte_final.tex
17 biber reporte_final
18 pdflatex reporte_final.tex
19 pdflatex reporte_final.tex
```

Listing B.1: Secuencia completa de reproducción

Apéndice C

Fragmentos de Código Esenciales

Esta sección presenta el código completo de las cinco funciones más importantes del proyecto.

C.1 Función `resolver_nombre` (`fusion.py`)

```
1 def resolver_nombre(row):
2     """
3     Resuelve conflictos de nombre entre SIDER y PubChem IUPAC.
4     Estrategia: Trust-One-Source con cascada de prioridad.
5     Prioridad: nombre SIDER > nombre IUPAC > "desconocido"
6     """
7     sider = str(row["drug_name"]).strip() if pd.notna(row["drug_name"])
8         else ""
9     iupac = str(row["iupac_name"]).strip() if pd.notna(row["iupac_name"])
10         else ""
11     if sider and sider.lower() not in ("nan", "none", ""):
12         return sider
13     if iupac and iupac.lower() not in ("nan", "none", ""):
14         return iupac
15     return "desconocido"
```

Listing C.1: Estrategia Trust-One-Source para resolución de nombres de fármacos

C.2 Función clasificar_frecuencia (limpieza.py)

```
1 def clasificar_frecuencia(s):
2     """
3     Convierte etiquetas cualitativas y valores numericos de frecuencia
4     de reacciones adversas a categorias MedDRA estandarizadas.
5     Sigue la convencion ICH E2C y GVP Module VI (EMA, 2017).
6     """
7     if pd.isna(s):
8         return None
9     s = str(s).strip().lower()
10    if s in SEVERITY_MAP:
11        return SEVERITY_MAP[s]
12    # Frecuencias numericas (porcentaje): clasificar por umbral MedDRA
13    m = re.match(r"^(\d+(?:\.\d+)?)\s*%?$", s)
14    if m:
15        pct = float(m.group(1))
16        if pct ≥ 10:    return "very_common"    # ≥ 1/10
17        if pct ≥ 1:     return "common"         # ≥ 1/100
18        if pct ≥ 0.1:   return "uncommon"       # ≥ 1/1,000
19        if pct > 0:     return "rare"           # ≥ 1/10,000
20    return None
```

Listing C.2: Clasificación de etiquetas de frecuencia de meddra_freq.tsv a categorías MedDRA

C.3 Funciones de validación y canonicalización de SMILES (limpieza.py)

```
1 def smiles_ok(s):
2     """
3     Valida un SMILES en dos niveles:
```

```
4      1. Sintactico: MolFromSmiles() != None y n_atoms > 0
5      2. Quimico: SanitizeMol() verifica valencias y aromaticidad
6      Nota: el nivel 2 es CRITICO porque MolFromSmiles() acepta
7      algunas moléculas con valencias inválidas sin lanzar excepción.
8      """
9
10     try:
11         mol = Chem.MolFromSmiles(str(s))
12         if mol is None or mol.GetNumAtoms() == 0:
13             return False
14         Chem.SanitizeMol(mol)
15         return True
16     except Exception:
17         return False
18
19 def canonicalizar_smiles(s):
20     """
21     Convierte cualquier SMILES válido a su representación canónica RDKit
22     .
23     Garantiza que la misma molécula siempre produce el mismo string,
24     independientemente del software que genere el SMILES original.
25     Esto es esencial para que los Morgan fingerprints sean reproducibles
26     .
27     """
28     try:
29         mol = Chem.MolFromSmiles(str(s))
30         if mol is not None:
31             return Chem.MolToSmiles(mol)
32     except Exception:
33         pass
34     return s
```

Listing C.3: Pipeline de validación química y canonicalización de SMILES con RDKit

C.4 Calculo de fingerprints Morgan y similitud Tanimoto (análisis.py)

```
1 from rdkit.Chem import AllChem
2 from rdkit import DataStructs
3
4 # --- Calculo de fingerprints ---
5 def calcular_fp(smiles_str):
6     """ECFP4: radio=2, 1024 bits, sin features farmacofóricos (ECFP, no
7         FCFP)."""
8     try:
9         mol = Chem.MolFromSmiles(smiles_str)
10        if mol:
11            return AllChem.GetMorganFingerprintAsBitVect(
12                mol, radius=2, nBits=1024, useFeatures=False
13            )
14        except Exception:
15            pass
16        return None
17
18 # --- Similitud Tanimoto entre dos fingerprints ---
19 def tanimoto(fp1, fp2):
20     """
21     Coeficiente de Tanimoto (Jaccard para bits):
22     
$$T(A,B) = |A \cap B| / |A \cup B| = c / (a + b - c)$$

23     Umbral de similitud significativa:  $T \geq 0.4$  (Maggiore et al., 2014)
24     """
25     return DataStructs.TanimotoSimilarity(fp1, fp2)
26
27 # Aplicacion: matriz de similitud para n farmacos
28 fps_list = [calcular_fp(s) for s in df["smiles"].unique()]
29 fps_list = [fp for fp in fps_list if fp is not None]
```

```
29
30 n = len(fps_list)
31 sim_matrix = np.zeros((n, n))
32 for i in range(n):
33     for j in range(n):
34         sim_matrix[i, j] = tanimoto(fps_list[i], fps_list[j])
```

Listing C.4: Cálculo de Morgan fingerprints ECFP4 y similitud Tanimoto entre pares

C.5 Pipeline de análisis PCA + k-means (análisis.py)

```
1 from sklearn.decomposition import PCA
2 from sklearn.cluster import KMeans
3 from sklearn.metrics import silhouette_score
4
5 # Matriz de fingerprints: (1556, 1024) binaria
6 fp_mat = np.array([list(fp) for fp in fps_list]) # shape (n, 1024)
7
8 # PCA: reduccion a 2 componentes para visualizacion
9 pca = PCA(n_components=2, random_state=42)
10 coords_2d = pca.fit_transform(fp_mat)
11 # PC1 explica 6.08% | PC2 explica 3.76% | Total = 9.84%
12
13 # Evaluacion de k optimo (sobre 50 PCs para eficiencia)
14 coords_50 = PCA(n_components=50, random_state=42).fit_transform(fp_mat)
15 for k in range(2, 8):
16     km = KMeans(n_clusters=k, random_state=42, n_init=10)
17     labels = km.fit_predict(coords_50)
18     sil = silhouette_score(coords_50, labels, sample_size=500,
19                             random_state=42)
19     # k=2: sil=0.4035 (optimo estadistico)
20     # k=5: sil=0.0179 (eleccion por dominio farmacologico)
```

```
21
22 # Clustering final con k=5 (justificacion: 5 clases farmacologicas
   principales)
23 K = 5
24 km_final = KMeans(n_clusters=K, random_state=42, n_init=10)
25 clusters = km_final.fit_predict(fp_mat)
```

Listing C.5: Reducción PCA y clustering k-means sobre fingerprints moleculares